

VNiVERSiDAD D SALAMANCA

Escuela Politécnica Superior de Ávila

Departamento de Ingeniería Cartográfica y del Terreno

Máster Universitario en

Modelización de Sistemas Hídricos



Trabajo Fin de Máster

Estudio multiescala temporal del rendimiento y capacidad predictiva del algoritmo Prophet en cuencas hidrográficas en régimen natural

Autor: Alejandro Dorta Estévez

Director/es: Dra. M^a Carmen Patino Alonso

Dr. Santiago Zazo del Dedo

Ávila, julio de 2023

Agradecimientos

A mis padres y a toda mi familia, gracias por apoyarme durante la etapa académica que hoy culmina. Agradecer en especial a los tutores, Carmen y Santiago, por su encomiable apoyo durante la realización de este trabajo. A los profesores que durante mi etapa académica me han enseñado a cuestionar e ir más allá de lo abordado en sus clases.

Índice

Resumen.....	8
Abstract.....	9
1 Introducción.....	10
2 Objetivos.....	14
3 Materiales y métodos	15
3.1 Casos de estudios	15
3.2 Metodología	17
3.2.1 Entorno de trabajo	22
3.3 Modelos predictivos	23
3.3.1 Prophet	23
3.3.2 ARIMA.....	27
3.3.3 SARIMA	29
3.4 Coeficientes de ajuste	30
3.4.1 Error medio absoluto (MAE).....	30
3.4.2 Raíz del error cuadrático medio (RMSE)	31
3.4.3 Índice de Nash-Sutcliffe (NSE)	32
3.5 Criterio de información de Akaike (AIC)	33
3.6 Exponente de Hurst	34
4 Resultados.....	35
4.1 Escala anual.....	35
4.2 Escala mensual.....	44
5 Aplicabilidad de los modelos.....	55
5.1 Adaja	55
5.2 Mijares.....	58
6 Conclusiones y futuras líneas de trabajo.....	61
7 Bibliografía.....	63

Índice de Figuras

Figura 1.	Demarcación hidrográfica del Duero.	16
Figura 2.	Demarcación hidrográfica del Júcar	17
Figura 3.	Flujo de trabajo para el ajuste de los diferentes modelos.	21
Figura 4.	Interfaz de MLflow.	23
Figura 5.	Esquema de validación cruzada.	27
Figura 6.	Resultados del test ADF para la serie anual de Adaja.	35
Figura 7.	Serie histórica anual. Estación 2046-Adaja.	36
Figura 8.	Resultados del ajuste del modelo ARIMA (0,0,0) a la serie histórica anual de Adaja.	37
Figura 9.	Resultados del ajuste del modelo Prophet a la serie histórica anual de Adaja. Modelo Prophet_1.	38
Figura 10.	Resultados del test ADF para la serie anual de Mijares.	39
Figura 11.	Serie histórica anual. Estación 8030 - Mijares.	40
Figura 12.	Resultados del ajuste del modelo ARIMA (1,0,1) a la serie histórica anual de Mijares.	41
Figura 13.	Resultados del ajuste del modelo Prophet a la serie histórica anual de Mijares. Modelo Prophet_2.	42
Figura 14.	Resultados del test ADF para la serie mensual de Adaja.	44
Figura 15.	Serie histórica mensual. Estación 2046 - Adaja.	45
Figura 16.	Resultados del ajuste del modelo SARIMA (2,0,2)(1,0,1)[6] a la serie histórica mensual de Adaja.	46
Figura 17.	Resultados del ajuste del modelo SARIMA (2,0,2)(1,0,1)[6] a la serie histórica mensual de Adaja. Periodo de validación.	46
Figura 18.	Resultados del ajuste del modelo Prophet a la serie histórica mensual de Adaja. Modelo Prophet_1.	47
Figura 19.	Resultados del ajuste del modelo Prophet a la serie histórica mensual de Adaja. Modelo Prophet_1. Periodo de validación.	48
Figura 20.	Resultados del test ADF para la serie mensual de Mijares.	49
Figura 21.	Serie histórica mensual. Estación 8030 - Mijares.	50
Figura 22.	Resultados del ajuste del modelo ARIMA (5,0,0) a la serie histórica mensual de Mijares.	51
Figura 23.	Resultados del ajuste del modelo ARIMA (5,0,0) a la serie histórica mensual de Mijares. Periodo de validación.	51

Figura 24. Resultados del ajuste del modelo Prophet_2 a la serie histórica mensual de Mijares.....	52
Figura 25. Resultados del ajuste del modelo Prophet_2 a la serie histórica mensual de Mijares. Periodo de validación.....	52
Figura 26. Evolución de las aportaciones y demanda acumuladas para la UTE de Adaja, año 2019.	57
Figura 27. Evolución de las aportaciones y demanda acumuladas para la UTE de Adaja, año 2020.	57
Figura 28. Superficie regada en la UTE de Mijares-Plana de Castellón. Fuente: Plan Especial de Sequía (2018).	58
Figura 29. Evolución de las aportaciones y demanda acumuladas para la UTE de Mijares-Plana de Castellón, año 2019.	59
Figura 30. Evolución de las aportaciones y demanda acumuladas para la UTE de Mijares-Plana de Castellón, año 2020.	60

Índice de Tablas

Tabla 1. Interpretación de los valores del exponente de Hurst.....	34
Tabla 2. Estadísticos de la serie histórica anual de Adaja.	36
Tabla 3. Estadísticos de la serie histórica anual de Mijares.....	40
Tabla 4. Resumen de resultados para la escala anual.	43
Tabla 5. Predicciones anuales.	43
Tabla 6. Estadísticos de la serie histórica mensual de Adaja.	45
Tabla 7. Estadísticos de la serie histórica mensual de Mijares.....	50
Tabla 8. Coeficientes de ajuste obtenidos para los modelos mensuales.	53
Tabla 9. Predicciones mensuales.	54
Tabla 10. Origen de los recursos en la UTE 10.3 - Adaja.....	56
Tabla 11. Demanda ecológica para el tramo del embalse Las Cogotas.	56
Tabla 12. Demanda agraria para la UTE de Mijares-Plana de Castellón.....	59
Tabla 13. Demanda ecológica para el tramo del embalse de Arenós.	59

Resumen

Título: Estudio multiescala temporal del rendimiento y capacidad predictiva del algoritmo Prophet en cuencas hidrográficas en régimen natural.

Autor: Alejandro Dorta Estévez

Palabras clave: Hidrología superficial, Hidrología estocástica, Prophet, ARIMA, Series temporales, Series de aportaciones

Este Trabajo evalúa el rendimiento y la capacidad predictiva del algoritmo de predicción de series temporales Prophet, a escala anual y mensual, en la predicción de aportaciones en dos ríos en régimen natural y con diferente comportamiento temporal. Los ríos de estudio se encuentran ubicados en la cuenca hidrográfica del Duero y del Júcar. Las series temporales modeladas comprenden un periodo de 77 años, para la estación de aforos de Adaja (Duero) y 73 años hidrológicos para la estación ubicada en Mijares (Júcar). Para la evaluación del rendimiento del modelo se han empleado como modelos base, varios enfoques basados en modelos ARIMA, siendo ajustados empleando el marco metodológico de Box-Jenkins. Los hiperparámetros del modelo Prophet se han ajustado empleando el método de validación cruzada, para el cual se ha implementado en la librería el coeficiente de eficiencia del modelo de Nash-Sutcliffe (NSE). El rendimiento y la capacidad predictiva del algoritmo Prophet se ha evaluado mediante el Error Medio Absoluto (MAE), el Error Cuadrático Medio (RMSE) y el coeficiente de eficiencia del modelo de Nash-Sutcliffe (NSE). Los resultados obtenidos sugieren que, en general, no hay diferencias significativas entre ambos enfoques de modelado, identificándose varias debilidades del modelo Prophet para su aplicación en la predicción hidrológica. Entre ellas, destacan la ausencia de una componente autorregresiva y la simulación de la estacionalidad como una función variable a lo largo del tiempo. Además, se ha evaluado la aplicabilidad de los modelos Prophet para la gestión de los recursos hídricos, como herramienta de apoyo a la decisión para la elaboración de planes de asignación de recursos hídricos en base a las demandas.

Abstract

Title: Temporal multiscale study of the performance and predictive capacity of the Prophet algorithm in natural regime watersheds.

Author: Alejandro Dorta Estévez

Keywords: Surface-water hydrology, Stochastic hydrology, Prophet, ARIMA, Time series, Streamflow series.

This study evaluates the performance and predictive capacity of the Prophet time series prediction algorithm, at annual and monthly scales, in the prediction of streamflow in two rivers in a natural regime and with different temporal behaviour. The rivers under study are located in the Duero and Júcar river basins. The time series modelled cover a period of 77 hydrological years for the Adaja (Duero) gauging station and 73 hydrological years for the station located at Mijares (Júcar). For the evaluation of the model performance, several approaches based on ARIMA models have been used as base models, being adjusted using the Box-Jenkins methodological framework. The hyperparameters of the Prophet model have been adjusted using the cross-validation method, for which the Nash-Sutcliffe model efficiency coefficient (NSE) has been implemented in the library. The performance and predictive ability of the Prophet algorithm has been evaluated using the Mean Absolute Error (MAE), the Root Mean Square Error (RMSE) and the Nash-Sutcliffe model efficiency coefficient (NSE). The results obtained suggest that, in general, there are no significant differences between the two modelling approaches, with several weaknesses of the Prophet model being identified for its application in hydrological forecasting. These include the absence of an autoregressive component and the simulation of seasonality as a time-varying function. In addition, the applicability of the Prophet models for water resources management has been evaluated, as a decision support tool for the development of water allocation plans based on demands.

1 Introducción

El aumento de la variabilidad climática es uno de los efectos observables del cambio climático, según los expertos (Seager et al., 2019). Este aumento de la variabilidad climática, a su vez, conlleva un aumento de la magnitud y la frecuencia de aparición de eventos extremos (Donat et al., 2016; Requena et al., 2023). En consecuencia, los sistemas y recursos hidrológicos también están sufriendo cambios, entre ellos, el aumento de la magnitud y frecuencia de los eventos hidrológicos extremos, como denominador común (Molina y Zazo, 2018).

Los efectos del cambio climático se pueden apreciar también en la alteración de los patrones de precipitación a lo largo del territorio (Djebou y Singh, 2016; Garijo y Mediero, 2019) y la variación en los ciclos y disponibilidad de recursos hidrológicos.

Estos cambios en los patrones de las precipitaciones pueden dar lugar a periodos de sequías cada vez más frecuentes, debido a la irregularidad de la precipitación, derivando en una insuficiencia en los recursos hídricos, incapaces de satisfacer las diferentes demandas. Otros factores, como el incremento en las temperaturas (Lorenzo y Alvarez, 2022) y una alta evapotranspiración, conllevarán un aumento de la demanda de recursos. En este sentido, en el actual contexto climático, con predicciones de reducción de la escorrentía entre un 10 y el 30% en España durante el siglo XXI (Estrela et al., 2012), gana gran importancia la correcta gestión de unos recursos cada vez más escasos.

Por otro lado, la demanda de agua apta para el consumo ya sea para el abastecimiento urbano o para el sector agrario, depende de la disponibilidad estacional de agua. Esto conlleva que la gestión del agua debe llevarse a cabo mediante planes a corto plazo y no mediante planes hidrológicos interanuales (Aguilera et al., 2019).

En este contexto de competencia por el agua, las decisiones de gestión hídrica son fundamentales para conservar la productividad agraria y los recursos naturales. Es preciso destacar que el sector agrario, es el responsable del setenta por ciento del consumo de los recursos hídricos de nuestro país, y será

uno de los más afectados en los próximos años (Jimenez-Donaire et al., 2020). Es, por tanto, de vital importancia, el fomento de la toma de decisiones que permitan la adaptación de los diferentes entes implicados en el ciclo integral del agua a este contexto, derivado del cambio climático. En este sentido, durante los últimos años se está apostando desde las instituciones por la modernización del sector del agua, mediante el reparto de ayudas económicas para el apoyo de nuevas inversiones. Un claro ejemplo es el Proyecto Estratégico para la Recuperación y Transformación Económica (PERTE), con énfasis en la digitalización del ciclo del agua, dotado con 1.700 millones, de los cuales 200 millones son destinados para el regadío. Entre los objetivos principales del PERTE está la digitalización en el regadío, mediante la implantación de contadores en las tomas de agua y en parcelas, mejorar los sistemas de control de la humedad del suelo y automatización de los sistemas de riego. También se incluye una inversión de 225 millones de euros con el objetivo de modernizar e impulsar la digitalización en los organismos de cuenca y los Sistemas Automáticos de Información Hidrológica.

En los últimos años, debido a esta tendencia por la digitalización, existe una gran necesidad de métodos predictivos potentes y fiables para la simulación y predicción del comportamiento hidrológico de los recursos hídricos. Debido a estas necesidades, durante los últimos años se han venido desarrollando y mejorando los modelos predictivos existentes (Shoaib et al., 2016; Yaseen et al., 2018) para entre otros aspectos, “gestionar” la no estacionariedad presente, derivada del cambio climático.

La predicción de caudales es importante debido a su aplicación en la gestión de inundaciones y recursos hídricos. Entre sus aplicaciones principales se incluyen la predicción de inundaciones y sequías, el riego y la explotación de embalses, por lo que la mejora de las previsiones hidrológicas en varias escalas temporales es de gran utilidad (Speight et al., 2021).

Los métodos predictivos de series temporales hidrológicas han venido empleándose ampliamente en Hidrología. Tradicionalmente, se han clasificado en dos grandes grupos: Paramétricos y no paramétricos. Los enfoques paramétricos o clásicos, se centran en modelos autorregresivos y modelos ARIMA (Modelo autorregresivo integrado de media móvil), (Salas et al., 1980).

Algunos ejemplos del uso de modelos ARIMA en el ámbito de la Hidrología se detallan en (Gurnell et al., 1992; Khan et al., 2020; Nozari y Tavakoli, 2020; Wang et al., 2014). También han sido empleados en la predicción de nacimientos (Saboia, 1977) y en las ciencias de la información (Tague et al., 1975).

Para la modelización de la componente estacional presente en las series hidrológicas (Salas et al., 1980) se emplea la variante SARIMA (Modelo autorregresivo integrado de media móvil estacional, por sus siglas en inglés) (Chaturvedi et al., 2022; Valipour, 2015). Los modelos SARIMA cuentan con un gran número de aplicaciones para la modelización de series a escala mensual (Dastorani et al., 2016; Khatibi et al., 2014; Modarres, 2007; Valipour, 2015).

Los modelos no paramétricos se han venido desarrollado principalmente en las últimas décadas. Estos modelos se caracterizan por no hacer suposiciones sobre las distribuciones de probabilidad. Entre estos destacan el método secuencial de índices (Kendall y Dracup, 1991) y el remuestreo k-próximo (KNNR) (Lee y Ouarda, 2011).

La precisión de los modelos de predicción requiere, por una parte, hacer frente a la aleatoriedad intrínseca de las series temporales hidrológicas y, por otra, incorporar la incertidumbre de esas predicciones.

A la par que estos métodos, con el auge de la Inteligencia Artificial, han surgido nuevos métodos de mayor complejidad, como las redes neuronales y los modelos híbridos. Estos modelos requieren de un alto grado de conocimiento para su correcto análisis e interpretabilidad. Sin embargo, no se han encontrado diferencias significativas entre enfoques clásicos y el empleo de modelos híbridos o redes neuronales (Papacharalampous et al., 2019). A raíz de este auge, en 2017 surge el algoritmo de código abierto Prophet (Taylor y Letham, 2018), desarrollado por Meta, para la predicción de series temporales. Éste, se basa en un modelo aditivo en el que las tendencias se combinan con componentes estacionales y días festivos. Este algoritmo nace con el objetivo de satisfacer las necesidades de negocio de Meta, cuya necesidad era producir previsiones fiables para la planificación y la fijación de objetivos (actividad de los usuarios, gustos, etc.). Se caracteriza por su flexibilidad y agilidad de uso, siendo estas, además, sus principales ventajas.

Sin embargo, a pesar de ser ampliamente empleado en campos como la industria y en el marketing digital, hasta ahora, solo se han detallado un reducido número de aplicaciones hidrometeorológicas. Algunos ejemplos de su uso en estos ámbitos se detallan en (Aziz et al., 2022; Chaturvedi et al., 2022; Navratil y Kolkova, 2019) donde es empleado para predicciones económicas, hasta la predicción de casos de coronavirus (Aditya Satrio et al., 2021). Su uso en la predicción del nivel de aguas subterráneas se encuentra detallada en (Aguilera et al., 2019), con resultados satisfactorios. Otros investigadores, como (Papacharalampous y Tyrallis, 2018a; Papacharalampous y Tyrallis, 2020), han evaluado su rendimiento en la predicción del caudal en ríos a siete días y a un año vista, respectivamente, comparándolo frente a diferentes modelos como los Bosques Aleatorios o ARFIMA (Modelo autorregresivo integrado de media móvil fraccional). Destaca también la predicción de precipitaciones y temperatura detalladas en (Hossain et al., 2022; Papacharalampous et al., 2018b), donde Prophet obtuvo resultados satisfactorios en comparación con otros métodos de series temporales univariantes. Por último, se han detallado aplicaciones en la simulación de la escorrentía superficial (Xiao et al., 2022) y sequías (Basak et al., 2022).

Dada su limitada aplicación en campo de la hidrología superficial, este Trabajo Fin de Máster (TFM) aspira, como objetivo principal, a evaluar su rendimiento y capacidad predictiva en cuencas hidrográficas en régimen natural a diferentes escalas temporales. Además, la agilidad de Prophet, permite su integración en herramientas de apoyo a la decisión, cada vez más empleadas (Chapman et al., 2018). Esto facilitaría el empleo de este tipo de modelos por las personas encargadas de la toma de decisiones, siendo una de sus ventajas frente a modelos con mayor complejidad, como las redes neuronales.

2 Objetivos

El Objetivo General de este Trabajo Fin de Máster es evaluar el rendimiento y capacidad predictiva en cuencas hidrográficas en régimen natural del algoritmo Prophet (Taylor y Letham, 2018), comparándolo frente a enfoques genéricos ARIMA.

Para ello, será necesario la consecución de los siguientes Objetivos Específicos:

1. Procesar y segmentar series temporales de datos hidrológicos a distintas escalas y con comportamiento temporal diferenciados.
2. Modelar mediante el algoritmo Prophet enfoques genéricos ARIMA de series temporales de aportaciones de cuencas en régimen temporal para diferentes escenarios y escalas temporales.
3. Evaluar el rendimiento y capacidad predictiva del algoritmo Prophet mediante indicadores como Error Medio Absoluto (MAE), Raíz del Error Cuadrático Medio (RMSE) y el Coeficiente de Eficiencia del modelo de Nash-Sutcliffe (NSE).

3 Materiales y métodos

3.1 Casos de estudios

El territorio español se caracteriza por una marcada variabilidad de precipitaciones a lo largo su extensión. Sin embargo, en el conjunto del país, en el periodo (1961-2018), se observan precipitaciones similares a las de hace unos años, tanto a escala anual como mensual (Romero Fresneda et al., 2020). Por provincias, en el periodo 1961-2018, según la media de estaciones en el territorio, se observa una disminución de las precipitaciones en León, Ávila, Las Palmas y Santa Cruz de Tenerife, entre otras (Romero Fresneda et al., 2020). Sin embargo, las predicciones para el 2050, señalan incrementos positivos en la precipitación media anual para las Canarias occidentales, la Comunidad Valenciana y Navarra. El resto del territorio se caracterizará por la reducción de la precipitación de manera generalizada, con principal importancia en el noroeste peninsular (Mingarro López et al., 2021).

Dado este escenario de gran incertidumbre, se han considerado dos casos de estudios característicos, por su comportamiento temporal opuesto (dependiente frente a independiente). Los datos y casos de estudios considerados corresponden a:

- Estación de aforos con código 2046 Adaja (Duero).
- Estación de aforos con código 8030 Terde (Júcar).

La estación de aforos 2046 se encuentra en el municipio de Ávila, en la provincia de Ávila, en el cauce del río Adaja. Pertenece a la Confederación Hidrográfica del Duero y abarca una superficie de cuenca de 770 km². La serie histórica empleada comprende el periodo 1942-2019, con 77 años hidrológicos.

La Demarcación Hidrográfica del Duero es la de mayor superficie de la península Ibérica. En ella se encuentran los territorios comprendidos en la cuenca hidrográfica del río Duero, las aguas de transición en el estuario de Oporto y las costeras atlánticas asociadas. El territorio se encuentra compartido entre Portugal y España, gestionando esta una superficie de 78.888,85 km².

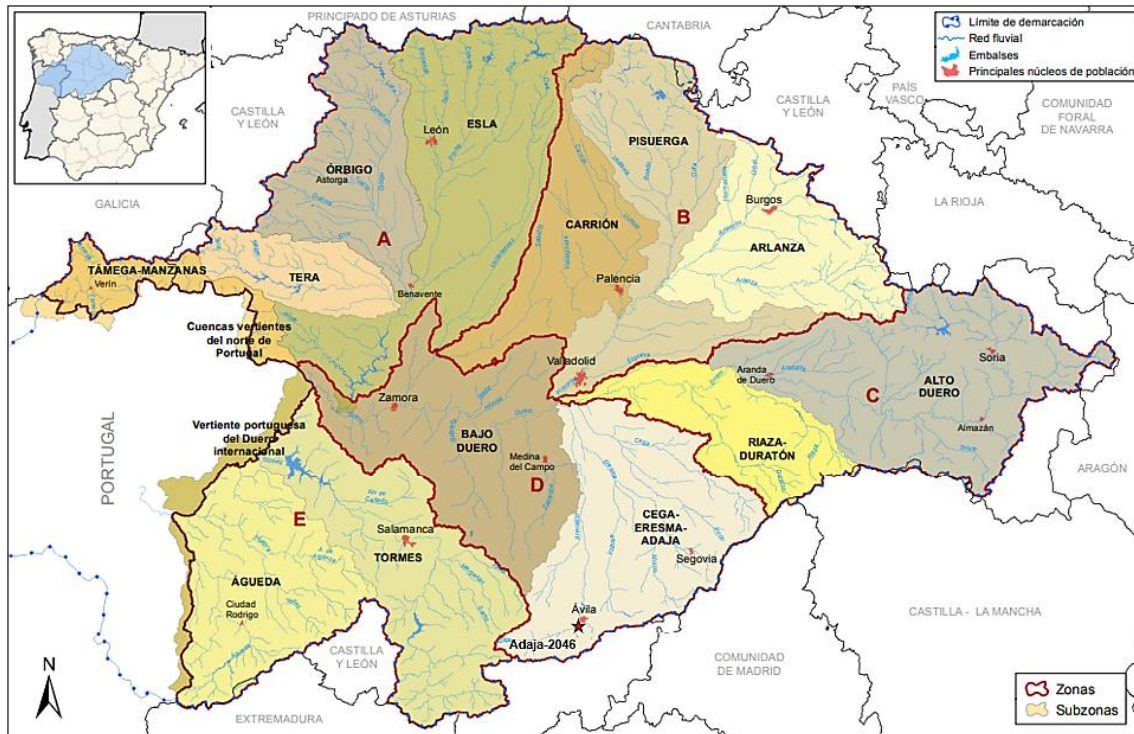


Figura 1. Demarcación hidrográfica del Duero. Fuente: Plan Hidrológico (2022).

Por su parte, la estación de aforos 8030 se encuentra en el municipio de Sarrión, en la provincia de Teruel, en el cauce del río Mijares. Pertenece a la Confederación Hidrográfica del Júcar y abarca una superficie de cuenca de 665 km². La serie histórica empleada comprende el periodo de 1946-2019, con 73 años hidrológicos. La Demarcación Hidrográfica del Júcar limita con las demarcaciones del Ebro y Segura al norte y sur, respectivamente, y del Tajo, Guadiana y Guadalquivir al oeste, bordeando al este con el Mediterráneo. La superficie total de la Demarcación, sin incluir las aguas costeras, es de 42.756 km².



Figura 2. Demarcación hidrográfica del Júcar. Fuente: Confederación Hidrográfica del Júcar (2023).

3.2 Metodología

De acuerdo con Salas et al. (1980), las series temporales hidrológicas cuentan con cuatro componentes:

1. Tendencias anuales y otros cambios deterministas.
2. Ciclos o cambios periódicos diarios y anuales.
3. Cambios casi periódicos.
4. Variaciones estocásticas.

Estas componentes se definen o componen de la siguiente manera:

1. Los errores sistemáticos y los cambios en la naturaleza por parte de los humanos o por procesos disruptivos, evolutivos o repentinos son los principales responsables de las tendencias a lo largo del año y de los cambios repentinos.

2. Las tendencias y ciclos aparentes son a menudo resultados de la casualidad, de fluctuaciones de muestreo en una serie de tiempo dada.
3. Los ciclos astronómicos son las causas básicas de la periodicidad y casi periodicidad en las características de las series temporales hidrológicas. Los procesos casi periódicos nunca se repiten de manera idéntica, como lo hacen los procesos periódicos. Los ciclos astronómicos del día y del año están presentes en todas las series temporales hidrológicas a escala diaria y anual.
4. Varios procesos en los entornos terrestres son responsables de la aleatoriedad (estocasticidad) en las series temporales (la conversión de calor, la opacidad atmosférica para las ondas de radiación entrantes y salientes, los procesos termodinámicos aleatorios, etc.). Estas fuentes de aleatoriedad producen variaciones en las series temporales, denominadas componentes estocásticos.

La modelización de las series temporales se ha llevado a cabo mediante modelos ARIMA y SARIMA para su comparación frente al rendimiento de Prophet. Se empleará el modelo ARIMA para la escala anual y el modelo SARIMA para la escala mensual, ya que cuenta con una componente que permite modelar la estacionalidad presente en las series hidrológicas a escala mensual (Salas et al., 1980).

El primer paso a realizar antes de la modelización es el preprocesamiento de los datos para ajustarlos al formato requerido por los modelos. Posteriormente, se determina si la serie temporal es estacionaria mediante el test Aumentado de Dickey-Fuller (Dickey y Fuller, 1979). Este test comprueba la hipótesis nula (H_0) de que existe una raíz unitaria en una muestra de una serie temporal. La hipótesis alternativa (H_1), indica que la serie es estacionaria. Cuanto más negativo sea el valor obtenido como resultado del test, mayor es el rechazo de la hipótesis nula. Conjuntamente se determinan las funciones de autocorrelación y autocorrelación parcial. Se analiza el comportamiento temporal de la serie en base a los resultados obtenidos. A continuación, se realiza el ajuste de los modelos ARIMA o SARIMA y Prophet mediante la previa determinación de los parámetros de mejor ajuste. Para la determinación de los parámetros de mejor

ajuste de los modelos ARIMA y SARIMA se ha empleado la metodología de Box-Jenkins, descrita en (Box y Jenkins, 1970).

El objetivo principal de este marco metodológico es facilitar el trabajo de análisis y predicción de series temporales, haciendo uso de técnicas que ayudan a explicar la estructura de las series y a realizar predicciones de estas. Permite escoger entre los modelos ARIMA y SARIMA que mejor se ajusten a la serie temporal observada, para la realización de predicciones.

La metodología se divide en los siguientes pasos:

1. **Identificación:** Se establecen los valores apropiados para los parámetros p, d, q, P, D, Q .
2. **Estimación:** Son estimados los parámetros incluidos en el modelo. En nuestro caso son estimados empleando el coeficiente AIC (Akaike, 1973), eligiendo la combinación de parámetros que presenta un menor valor del AIC.
3. **Verificación de diagnóstico:** Al seleccionar el modelo se debe comprobar si el modelo se ajusta a los datos. Se comprueban si los residuos obtenidos son ruido blanco.
4. **Predicción:** Se ajusta el modelo a la totalidad de la serie temporal. Generación de predicciones de la serie temporal

La metodología de ajuste del modelo Prophet es la siguiente:

1. **Ajuste manual de los hiperparámetros del modelo.** Tanteo de prueba y error verificando qué hiperparámetros tiene mayor influencia en el ajuste a la serie temporal.
2. **Estimación de los parámetros de mejor ajuste.** En base a la identificación de los hiperparámetros con mayor influencia en el ajuste del modelo se realizan pruebas con diferentes valores de cada uno de estos hiperparámetros. Los hiperparámetros de un modelo son definidos como los valores de las configuraciones utilizadas durante el proceso de entrenamiento. Estos valores no son obtenidos de los datos y no se pueden conocer sus valores óptimos a priori. De manera general, se emplean valores genéricos utilizados en problemas similares o son determinados mediante prueba y error.

3. **Validación cruzada.** Se realizan ajustes de varios modelos ajustados empleando los valores identificados anteriormente. Se determina el conjunto de valores que ofrecen un mejor ajuste.
4. **Verificación del ajuste.** Se ejecuta el modelo con los valores obtenidos del proceso de validación cruzada y se obtienen las métricas de ajuste.
5. **Predicción.** Se ajusta el modelo a la totalidad de la serie temporal. Se realiza una predicción hidrológica.

La Figura 3 resume la metodología empleada para el ajuste de los modelos ARIMA y Prophet, en los casos de estudios mencionados y las diferentes escalas temporales.

Debido a la variabilidad de los recursos hídricos en España y la incertidumbre propia de los sistemas hidrológicos (Molina et al., 2019), se ha establecido un horizonte de trabajo de dos años vista para la realización de predicciones.

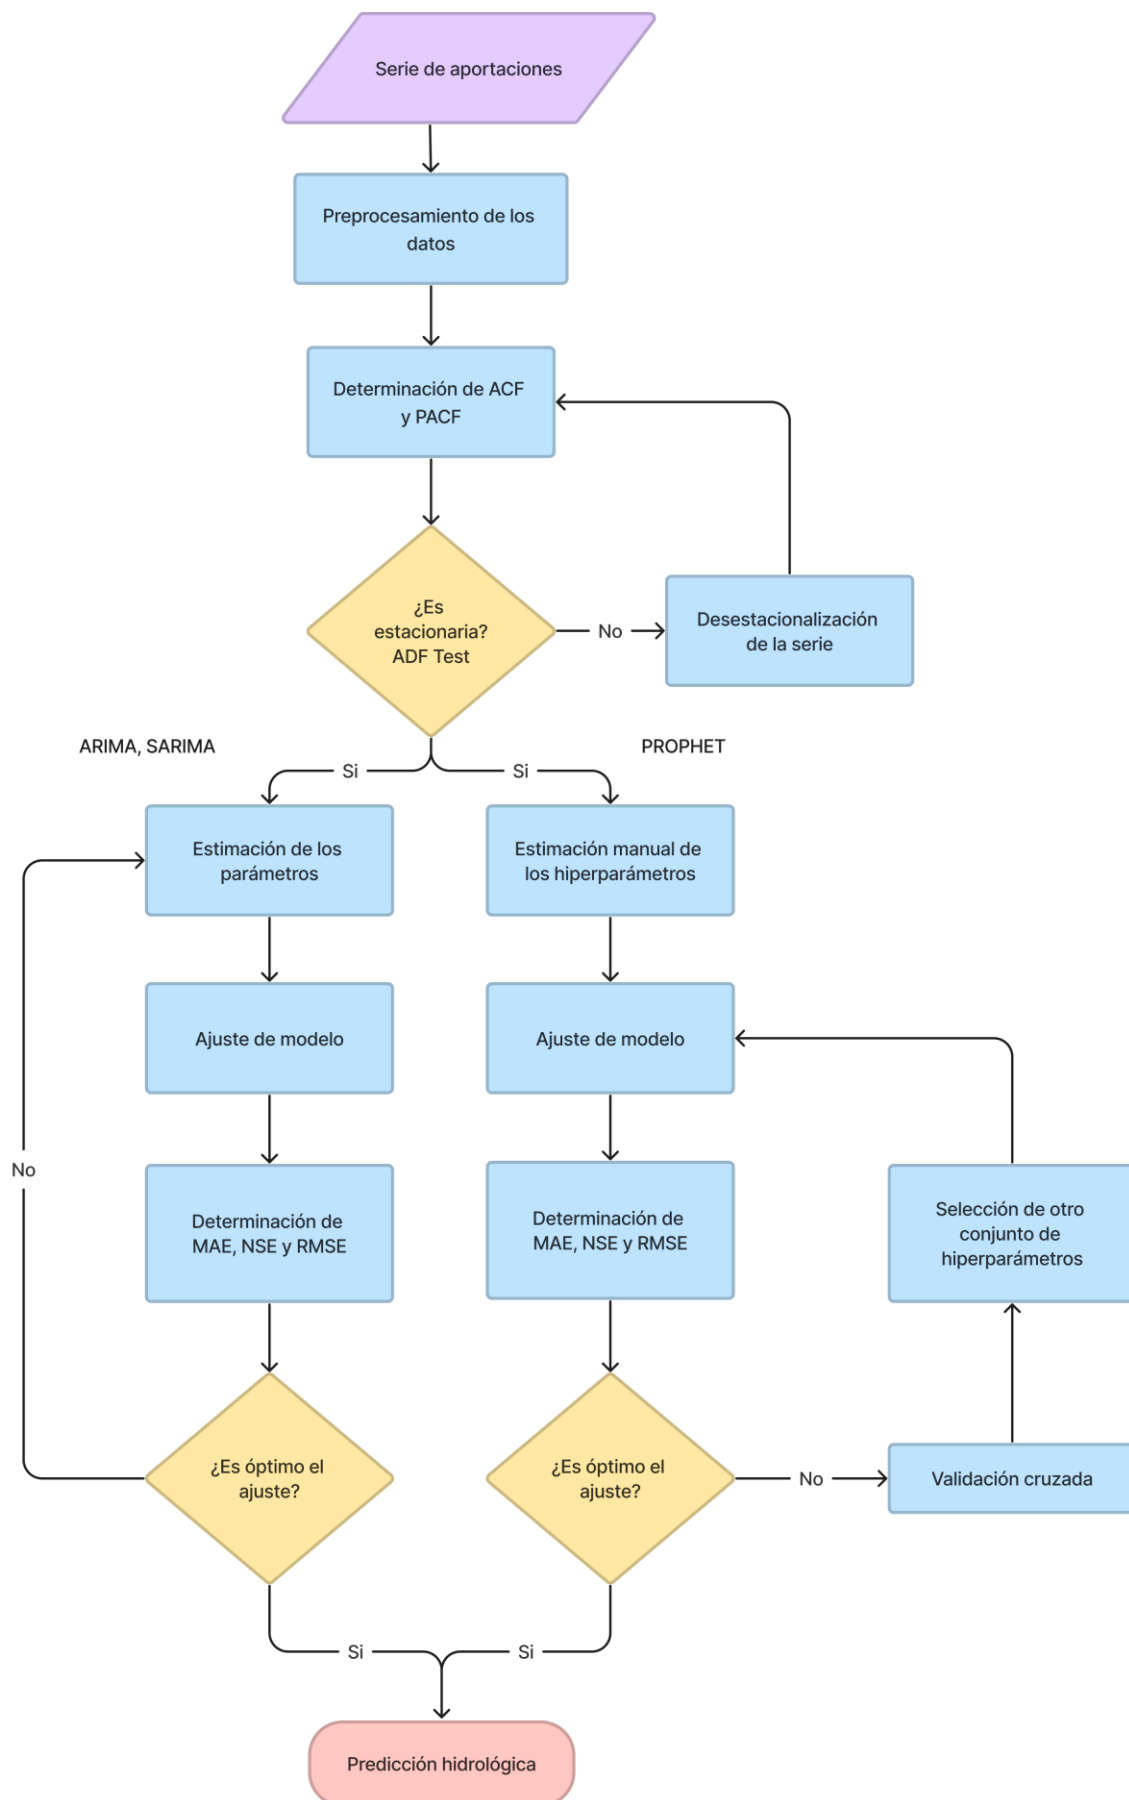


Figura 3. Flujo de trabajo para el ajuste de los diferentes modelos.

3.2.1 Entorno de trabajo

Se ha empleado el lenguaje de programación multipropósito Python y la distribución Anaconda. Se ha utilizado Jupyter Notebooks como entorno para el ajuste de los modelos, así como la realización de diferentes pruebas.

Se ha decidido emplear este lenguaje por la disponibilidad de un elevado número de librerías para el análisis de datos, con especial énfasis, en aquellas destinadas al tratamiento de datos hidrológicos, siendo un estándar en este ámbito. Además, es uno de los lenguajes en los que se encuentra implementada la librería de Prophet.

Las principales ventajas de Python frente a otros lenguajes son:

- Lenguaje débilmente tipado y con baja curva de aprendizaje.
- Gran cantidad de librerías y frameworks destinados al tratamiento de datos y modelos de Inteligencia Artificial.
- Puede ejecutarse en diferentes plataformas.

Entre sus desventajas destacan:

- Procesamiento lento. Tiempos de ejecución elevados para grandes proyectos.
- Consumo de memoria. En proyectos de gran dimensión realiza un consumo excesivo de recursos.

Los modelos ajustados, además de los parámetros de ajuste de cada uno de ellos han sido tratados empleando MLflow, una plataforma de código abierto destinada al ciclo de vida de los modelos de Machine Learning. Los modelos guardados en la plataforma pueden ser desplegados en un entorno productivo, poniendo a disposición de diferentes plataformas digitales las predicciones ofrecidas por el correspondiente modelo, lo que garantiza la rápida implementación de los modelos.

En la siguiente imagen (Figura 4) se puede ver un ejemplo de los diferentes modelos Prophet que han sido entrenados, con sus correspondientes coeficientes de ajuste.

<input type="checkbox"/>	Run Name	Created	Duration	Models	Metrics		
					MAE	NSE	RMSE
<input type="checkbox"/>	popular-stag-756	🟢 2 months ago	5.7s	🔗 Mijares-Me.../9	1.156	-0.925	1.556
<input type="checkbox"/>	amazing-fox-491	🟢 2 months ago	6.0s	🔗 Mijares-Me.../8	1.208	-1.077	1.616
<input type="checkbox"/>	dazzling-grouse-473	🟢 2 months ago	6.0s	🔗 Mijares-Me.../7	1.156	-0.925	1.556
<input type="checkbox"/>	mysterious-frog-801	🟢 2 months ago	7.5s	🔗 Mijares-Me.../6	1.32	-1.428	1.747
<input type="checkbox"/>	honorable-cow-396	🟢 2 months ago	4.9s	🔗 Adaja-Mens.../35	5.298	-0.009	7.94
<input type="checkbox"/>	nosy-cat-364	🟢 2 months ago	4.9s	🔗 Adaja-Mens.../34	6.492	-0.316	9.07
<input type="checkbox"/>	selective-rat-465	🟢 2 months ago	4.4s	🔗 Adaja-Mens.../33	7.653	-0.648	10.15
<input type="checkbox"/>	painted-snail-335	🟢 2 months ago	4.1s	🔗 Adaja-Mens.../32	5.298	-0.009	7.94
<input type="checkbox"/>	serious-deer-831	🟢 2 months ago	4.9s	🔗 Adaja-Mens.../31	5.217	0.009	7.87
<input type="checkbox"/>	bedecked-hog-387	🟢 2 months ago	4.3s	🔗 Adaja-Mens.../30	5.22	0.006	7.882
<input type="checkbox"/>	angry-rook-330	🟢 2 months ago	4.7s	🔗 Adaja-Mens.../29	5.113	0.039	7.752

Figura 4. Interfaz de MLflow.

3.3 Modelos predictivos

En este apartado se detallan los diferentes modelos aplicados para la predicción de las series hidrológicas.

3.3.1 Prophet

Prophet es una librería de código abierto para la predicción de series temporales desarrollada por el equipo de ciencia de datos de Meta. Aunque fue desarrollado con fines comerciales, funciona de manera adecuada datos de series temporales observados a escalas horarias, diarias, semanales y mensuales, que cuentan con una marcada estacionalidad.

Predice las series temporales como un modelo aditivo que combina la función de tendencia, la función de estacionalidad, los efectos de las vacaciones y un término de error. La expresión general del modelo es la siguiente:

$$Y(t) = g(t) + s(t) + h(t) + \epsilon_t \quad (1)$$

donde $g(t)$ y $s(t)$ representación la tendencia y la estacionalidad, mientras que $h(t)$ representa el efecto vacaciones y ϵ_t es el término de error.

En este trabajo no se empleará el efecto de las vacaciones, al considerarse como variable de entrada del modelo el valor de las aportaciones registradas por las estaciones de aforos.

Prophet es considerado como un modelo ágil para la predicción de series temporales, siendo este uno de los objetivos principales de su creación. Cuenta con varios hiperparámetros configurables, además de una opción de validación cruzada para su ajuste, teniendo en cuenta los errores de predicción. Además, permite la posibilidad de incluir regresores adicionales y diferentes opciones de personalización de la estacionalidad.

Prophet cuenta con dieciséis hiperparámetros, de entre los cuales se recomiendan ajustar los siguientes:

- **changepoint_prior_scale:** Es considerado como el parámetro de mayor impacto. Determina la flexibilidad de la tendencia y cuánto cambia la tendencia en los puntos de cambio de tendencia. Si el valor elegido es demasiado pequeño, la tendencia no se ajustará correctamente y la varianza que debería haber sido modelada con los cambios de tendencia acabará siendo tratada con el término de ruido. Si es demasiado grande, la tendencia se sobreajustará. Se recomienda emplear valores en el intervalo de [0,001, 0,5] para la mayoría de casos.
- **changepoint_range:** Es la proporción de la serie temporal en la que se permite que cambie la tendencia. Por defecto es 0,8.
- **seasonality_prior_scale:** Controla la flexibilidad de la estacionalidad. Un valor grande permite que la estacionalidad se ajuste a grandes fluctuaciones, un valor pequeño reduce la magnitud de la estacionalidad. Se recomienda emplear valores en el intervalo de [0,01, 10].
- **holidays_prior_scale:** Controla la flexibilidad para ajustar los efectos de las vacaciones. Se recomienda valores entre [0,01, 10]. En nuestro caso de estudio no ajustaremos este hiperparámetro, al no emplear la componente de vacaciones.
- **seasonality_mode:** Permite definir el modo de la estacionalidad. Las opciones son ['aditiva', 'multiplicativa']. Por defecto se establece una estacionalidad aditiva.

De acuerdo con Taylor y Letham (2018), las principales funcionalidades y ventajas de Prophet que se describen son.

- Detección automática de cambios de tendencia.
- Capacidad de trabajar con valores atípicos o nulos.
- Resulta intuitivo para el manejo por usuarios con reducidos conocimientos en modelización de series temporales.
- Buen ajuste del modelo a diferentes tipologías de series temporales, garantizando una buena capacidad predictiva.
- Ágil ajuste del modelo.

Validación cruzada

Uno de los principales problemas con los que nos enfrentamos al trabajar con modelos predictivos es el sobreajuste del modelo. El concepto de sobreajuste de un modelo hace referencia a la construcción de un modelo que se adapte perfectamente al conjunto de datos de entrenamiento, pero que luego no es capaz de generalizar correctamente valores desconocidos.

Para evitar el sobreajuste del modelo, se suelen emplear diversas técnicas, siendo una de ellas la validación cruzada (Refaeilzadeh y Tang, 2009). Esta técnica es ampliamente utilizada (Charilaou y Battat, 2022; Little et al., 2017; Nurhayati et al., 2014; Olewy y Hadi, 2021) y consiste en un método de remuestreo de datos con el objeto de evaluar la capacidad de generalización de los modelos predictivos para evitar el sobreajuste del modelo (Berrar, 2018). Otro método de remuestreo destacado es el bootstrapping (Efron, 1979), el cual consiste en el remuestreo de un único conjunto de datos con el objetivo de obtener muestras simuladas. Este método permite el cálculo del error estándar, intervalos de confianza y pruebas de hipótesis (Berrar, 2018).

Uno de los puntos más importantes a la hora de trabajar con modelos predictivos es encontrar el equilibrio entre el sobreajuste del modelo y el infraajuste (Berrar, 2018). Lo ideal a la hora de evaluar el modelo sería emplear datos nuevos de la misma población. Sin embargo, a veces no es posible realizar este tipo de validaciones, por lo que se suele estimar primero el rendimiento predictivo mediante métodos de remuestreo, como la validación cruzada.

Este procedimiento cuenta con los siguientes objetivos:

- Estimar el rendimiento del modelo aprendido a partir de los datos disponibles utilizando un algoritmo.
- Comparar el rendimiento de dos o más algoritmos diferentes y averiguar cuál es el mejor algoritmo para los datos disponibles.
- Comparar el rendimiento de las variantes de un modelo.

Hay diferentes métodos de validación cruzada, en nuestro caso emplearemos el denominado *K-Fold Cross Validation*, implementado en Prophet:

En la validación cruzada *K-Fold*, el conjunto de datos de aprendizaje disponible se divide en k subconjuntos de aproximadamente el mismo tamaño. Esta división se realiza mediante el muestreo aleatorio de casos del conjunto de aprendizaje sin reemplazo.

El modelo se entrena utilizando $k-1$ subconjuntos que, juntos, representan el conjunto de entrenamiento. A continuación, el modelo se aplica al subconjunto restante, que se denomina conjunto de validación, y se mide el rendimiento. Este procedimiento se repite hasta que cada uno de los subconjuntos haya servido como conjunto de validación. El detalle de este procedimiento se puede apreciar en la Figura 5.

La media de las mediciones de rendimiento de los conjuntos de validación es el rendimiento de validación cruzada.

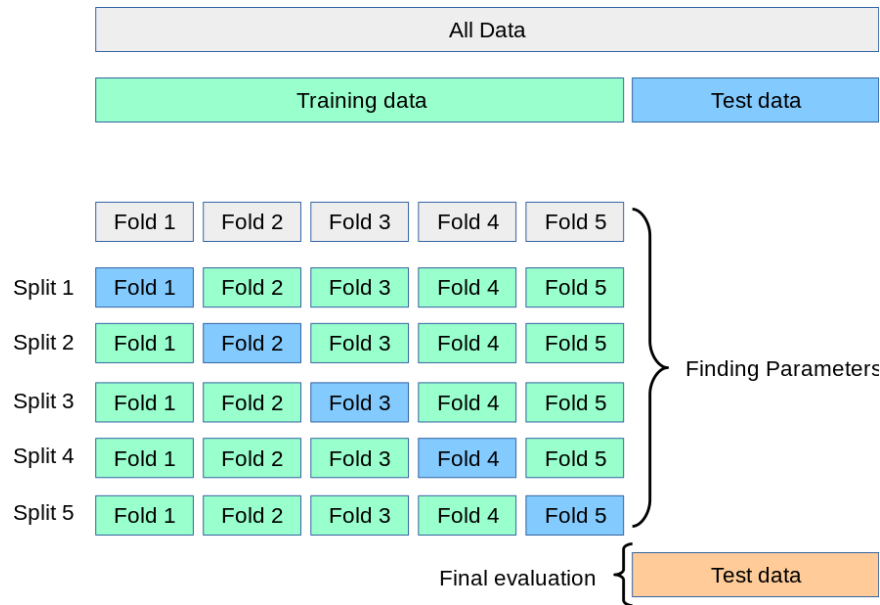


Figura 5. Esquema de validación cruzada. Fuente: Scikit-learn (2023).

3.3.2 ARIMA

ARIMA es un modelo autorregresivo de análisis estadístico que utiliza datos de series temporales para comprender mejor el conjunto de datos o predecir tendencias futuras.

Un modelo estadístico es autorregresivo si predice valores futuros basándose en valores pasados. Por ejemplo, un modelo ARIMA puede tratar de predecir futuras aportaciones de un río basándose en aportaciones pasadas.

Un modelo ARIMA cuenta con las siguientes componentes:

- **Autoregresión (AR):** se refiere a un modelo que muestra una variable cambiante que hace regresión sobre sus propios valores pasados.
- **Diferenciación (I):** representa la diferenciación de las observaciones originales para permitir que la serie temporal se convierta en estacionaria.
- **Media móvil (MA):** incorpora la dependencia entre una observación y un error residual de un modelo de media móvil aplicado a observaciones pasadas.

Cada componente de ARIMA se denomina con un parámetro con una notación estándar. Para los modelos ARIMA, la notación estándar es p , d y q , donde los valores enteros sustituyen a los parámetros para indicar el tipo de modelo ARIMA utilizado.

Los parámetros se definen como:

- **p** : el número de observaciones de retardo en el modelo, denominado como orden de retardo.
- **d** : el número de veces que se diferencian las observaciones originales, denominado grado de diferenciación.
- **q** : el tamaño de la ventana de la media móvil, denominado orden de la media móvil.

En un modelo ARIMA, un ARIMA (p,q) se define como se detalla en la Ecuación 2:

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + u_t - \theta_1 u_{t-1} - \theta_2 u_{t-2} - \dots - \theta_q u_{t-q} \quad (2)$$

donde los parámetros reales $\phi_1, \phi_2, \dots, \phi_p$ son denominados coeficientes autorregresivos, los parámetros reales $\theta_j (j=1, 2, \dots, q)$ son coeficientes de media móvil, y u_t es una secuencia independiente de ruido blanco. Normalmente la media de y_t es igual a cero, en caso contrario, $y'_t = y_t - \mu$ es usado en el modelo.

A continuación, se introduce el operador de desfase (B):

$$\phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p \quad (3)$$

$$\theta(B) = 1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q$$

Pudiendo ser simplificado el modelo de la siguiente manera:

$$\phi(B)y_t = \varphi(B)u_t \quad (4)$$

Si y_t no son estacionarios, podemos obtener a secuencia estacionaria z_t mediante la diferencia:

$$z_t = (1 - B)^d y_t = \nabla^d y_t \quad (5)$$

donde d es el número de diferencias regulares. Posteriormente, puede ser construido el modelo ARIMA (p,d,q) de y_t correspondiente.

3.3.3 SARIMA

SARIMA es una extensión del modelo ARIMA que admite explícitamente datos de series temporales univariantes con una componente estacional.

Este modelo añade tres nuevos parámetros para especificar la autoregresión (AR), la diferenciación (I) y la media móvil (MA) para la componente estacional de la serie, además de un parámetro adicional para el periodo de la estacionalidad.

Estos elementos estacionales son los siguientes:

- **P**: Orden autorregresivo estacional.
- **D**: Orden de diferencia estacional.
- **Q**: Orden de media móvil estacional.
- **s**: El número de intervalos temporales para un único periodo estacional.

El modelo SARIMA refleja la variación estacional en series de tiempo. Generalmente, la serie de tiempo original utiliza un operador de retardo B para procesar un SARIMA $(p,d,q) \times (P,D,Q)_s$.

Un modelo SARIMA puede construirse con el siguiente procedimiento. En primer lugar, se aplica la diferencia para eliminar la propiedad de la estacionalidad. Para obtener la secuencia estacionaria, se puede construir un modelo como sigue:

$$\phi_p(B)\Phi_p(B^s)(1-B)^d(1-B^s)^D y_t = \theta_q(B)\Theta_q(B^s)u_t \quad (6)$$

donde P es el coeficiente estacional de autocorrelación Q es el orden de la media móvil estacional, D es el número de diferencias estacionales y s es la duración de la temporada.

3.4 Coeficientes de ajuste

A continuación, se detallan cada uno de los métodos empleados para valorar los ajustes de los modelos a las series temporales. Para el cálculo de estos coeficientes se han implementado los métodos contemplados en el paquete Hydrostats, (Roberts et al., 2018), desarrollado en Python, en el entorno de trabajo.

3.4.1 Error medio absoluto (MAE)

El error medio absoluto (MAE) es una medida de los errores entre observaciones pareadas de un mismo fenómeno (Chai y Draxler, 2014). Es usado para comparar los errores en las observaciones de los valores predichos por un modelo frente a los observados.

La expresión para su cálculo es la siguiente:

$$MAE = \frac{1}{N} \sum_{i=0}^N |P_i - O_i| \quad (7)$$

donde O_i y P_i representan la muestra de tamaño N conteniendo las observaciones y predicciones del modelo, respectivamente.

Toma valores de infinito a 0, con cero indicando un ajuste perfecto del modelo. El valor del error medio absoluto obtenido se encuentra en la misma escala que las observaciones, es por lo tanto dependiente de la escala. Debido a esto, no se puede utilizar para hacer comparaciones entre valores pronosticados que utilizan diferentes escalas.

3.4.2 Raíz del error cuadrático medio (RMSE)

La raíz del error cuadrático medio (RMSE) representa la media cuadrática de las diferencias entre los valores predichos y los valores observados de un modelo (Chai & Draxler, 2014).

Las desviaciones entre estos valores son denominadas residuos cuando se realizan los cálculos sobre la muestra de datos utilizada para la estimación, y se denominan errores de predicción cuando son calculados fuera de esta muestra.

Se emplea para comparar los errores de predicción de distintos modelos para un conjunto de datos concreto y no entre conjuntos de datos, ya que sus valores dependen de la escala de los valores obtenidos del modelo.

Toma valores de infinito a 0, con cero indicando un ajuste perfecto del modelo. En general, un valor de RMSE más bajo es siempre mejor. Debemos de tener en cuenta que las comparaciones entre distintos tipos de datos no serían válidas porque la medida depende de la escala de los números utilizados.

El efecto de cada error en la predicción en el valor del RMSE es proporcional al tamaño del error al cuadrado; es, por tanto, que los errores más grandes tienen un mayor efecto en el valor final. El coeficiente RMSE es, por lo general, sensible a los valores atípicos.

Es obtenido mediante la siguiente expresión:

$$RMSE = \sqrt{\frac{\sum_{i=1}^N (O_i - P_i)^2}{N}} \quad (8)$$

donde O_i y P_i representan la muestra de tamaño N conteniendo las observaciones y predicciones del modelo, respectivamente.

3.4.3 Índice de Nash-Sutcliffe (NSE)

Propuesto por Nash y Sutcliffe (1970), el coeficiente de eficiencia del modelo de Nash-Sutcliffe (NSE) se calcula como uno menos el cociente de la varianza del error de las series modeladas dividido entre la varianza de los valores observados.

En la situación de un modelo perfecto, la varianza de error de estimación es igual a cero, y el valor de NSE resultante es igual a 1. Por el contrario, un modelo que produce una varianza del error de estimación igual a la varianza de la serie temporal observada da como resultado un valor de NSE igual a 0. El NSE puede tomar valores desde menos infinito a 1.

Un valor de NSE igual a cero (0) indica que el modelo tiene la misma capacidad predictiva que la media de la serie temporal en referencia a la suma del error cuadrático. Los valores negativos de NSE son obtenidos en aquellos casos en los que una serie temporal modelizada presenta una varianza de error de estimación significativamente mayor que la varianza de las observaciones.

Por lo tanto, los valores del NSE más cercanos a 1, sugieren un modelo con mayor capacidad predictiva.

La expresión para el cálculo del coeficiente NSE es la siguiente:

$$NSE = 1 - \frac{\sum_{i=1}^N (O_i - P_i)^2}{\sum_{i=1}^N (O_i - \bar{O})^2} = 1 - \left(\frac{RMSE}{SD} \right)^2 \quad (9)$$

donde \bar{O} es la media de los valores observados y SD , es la desviación estándar de las observaciones.

No hay definido un valor exacto del coeficiente a partir del cual se considere aceptable la capacidad predictiva de un modelo. Por esta razón, la literatura científica sugiere diferentes valores como umbrales de suficiencia del modelo, sugiriendo, por ejemplo, un valor de NSE igual 0,50 en Moriasi et al. (1983), y 0,65 en Ritter y Muñoz-Carpena (2013).

En este TFM se ha considerado como valor óptimo de NSE, un valor igual o superior a 0,65, en línea con lo propuesto en el estudio Ritter y Muñoz-Carpena (2013).

Por otro lado, una de las debilidades de Prophet es que no cuenta con este coeficiente implementado. Por ello, el desarrollo de este TFM se ha supuesto la implementación de este coeficiente, para llevar a cabo el proceso de validación cruzada.

3.5 Criterio de información de Akaike (AIC)

El criterio de información de Akaike (AIC) es un estimador del error de predicción empleado para cuantificar la calidad relativa de los modelos estadísticos para un conjunto de datos determinado (Akaike, 1973). En este sentido, AIC calcula la cantidad relativa de información perdida por un modelo, bajo el planteamiento de cuanto menor cantidad de información pierda un modelo, mayor será su calidad.

Contando con un modelo estadístico de un conjunto de datos, siendo k el número de parámetros estimados del modelo y \hat{L} el valor maximizado de la función de verosimilitud del modelo.

Obtenemos el valor de AIC de la siguiente manera:

$$AIC = 2k - 2 \ln(\hat{L}) \quad (10)$$

De un conjunto de modelos, serán escogidos aquellos con el valor de AIC mínimo. El AIC valora conjuntamente la bondad del ajuste, incluyendo una penalización por el número de parámetros del modelo, además del sobreajuste.

3.6 Exponente de Hurst

El exponente de Hurst es una medida de independencia de series temporales propuesta por Harold Edwin Hurst (1880-1978), para la distinción de series fractales.

La proposición del coeficiente de Hurst surge tras el descubrimiento que muchos fenómenos naturales presentan un comportamiento capaz de caracterizarse por un proceso aleatorio sesgado, en el cual existe una "memoria a largo plazo" entre las observaciones. La memoria a largo plazo hace referencia a la influencia de los sucesos de un periodo sobre sucesos posteriores.

Las ideas iniciales contempladas por Hurst, posteriormente fueron generalizadas por Benoit B. Mandelbrot, denominándolo análisis de rango reescalado. El coeficiente de Hurst se define como un método estadístico utilizado para evaluar la ocurrencia de eventos atípicos, con aplicaciones en el mundo de la hidrología (Koutsoyiannis, 2004; Mesa y Poveda, 1993; Salas et al., 1979) y finanzas, entre otros.

Este coeficiente toma valores de 0 a 1. Valores entre 0-0,5 indican una serie con alternancia entre valores altos y bajo con larga duración temporal, valores iguales a 0,5 indican una serie descorrelacionada, con independencia temporal. Por otro lado, valores entre 0,5 y 1, indican la presencia de dependencia temporal a largo plazo. Estos valores se detallan en la Tabla 1.

H	Interpretación
0 a 0,5	Serie temporal con cambio a largo plazo entre valores altos y bajos en pares adyacentes. Esta tendencia durará mucho tiempo en el futuro.
0,5	Serie descorrelacionada. Aplicable a las series donde los valores absolutos de las autocorrelaciones decaen con rapidez a cero.
0,5 a 1	Serie temporal con autocorrelación positiva a largo plazo. Presencia de dependencia temporal.

Tabla 1. Interpretación de los valores del exponente de Hurst.

En este caso, se realiza el cálculo del coeficiente de Hurst, de acuerdo con el marco metodológico expuesto en Salas et al., 1980.

4 Resultados

Las series anuales y mensuales de aportaciones registradas en las estaciones de aforo fueron procesadas, realizando el ajuste de modelos ARIMA y Prophet a la serie histórica. En este apartado se detallan los diferentes resultados obtenidos.

4.1 Escala anual

La serie anual de Adaja analizada corresponde al periodo de 1942-2019, englobando un total de 77 años hidrológicos. Se ha realizado una prueba de Dickey-Fuller Aumentada (Dickey y Fuller, 1979) para determinar la estacionariedad de la serie. El p valor obtenido es significativamente inferior a 0,05, por lo tanto, rechazamos la hipótesis nula (H_0) y consideramos que la serie es estacionaria. Los resultados obtenidos en el test se detallan en la Figura 6.

```
Augmented Dickey-Fuller Test:
ADF test statistic      -5.208607
p-value                0.000008
# lags used            1.000000
# observations         75.000000
critical value (1%)    -3.520713
critical value (5%)    -2.900925
critical value (10%)   -2.587781
Strong evidence against the null hypothesis
Reject the null hypothesis
Data has no unit root and is stationary
```

Figura 6. Resultados del test ADF para la serie anual de Adaja.

El valor del coeficiente de Hurst obtenido, 0,73, indica que la serie cuenta con un comportamiento dominado por la variación entre valores altos y bajos de manera sostenida en el tiempo. Esto se puede apreciar en el gráfico de la serie y la función de autocorrelación.

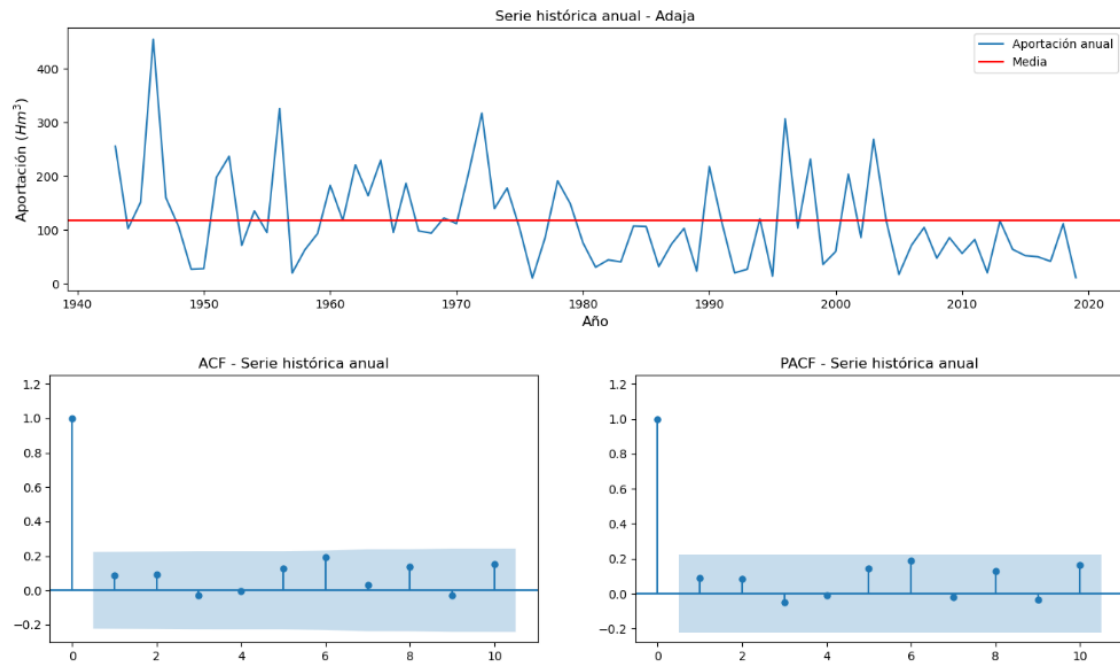


Figura 7. Serie histórica anual. Estación 2046-Adaja. En la parte superior se muestra la serie histórica. En la parte inferior se muestran las funciones de autocorrelación (ACF) y autocorrelación parcial (PACF). Intervalos de confianza al 95%.

En la serie histórica destacan los periodos de 1980 a 1995 y 2005-2010, con aportaciones anuales situadas por debajo de la media de la serie histórica. En la Tabla 2 se muestran los resultados obtenidos de los estadísticos de la serie.

Periodo	1942-2019, 77 años
Media	116,78 hm ³
Desviación estándar	86,6 hm ³
Coeficiente de variación	0,74
Coeficiente de asimetría	1,29
Exponente de Hurst	0,73

Tabla 2. Estadísticos de la serie histórica anual de Adaja.

Para la determinación de los parámetros (p, d, q) de los modelos ARIMA a ajustar, se obtuvieron los valores de las funciones de autocorrelación y autocorrelación parcial. Los resultados obtenidos indican que la serie es temporalmente independiente, como se puede apreciar en la Figura 7, al encontrarse los valores de la función de autocorrelación y la función de autocorrelación parcial dentro de los intervalos de confianza.

Dados los resultados obtenidos, los parámetros p y q óptimos del modelo ARIMA son iguales a 0.

Se decidió ajustar un modelo ARIMA $(0,0,0)$ a la serie temporal, empleando una amplitud del set de validación del modelo del treinta por ciento de las observaciones, abarcando un periodo de 1995-2019, con valores de veinticuatro años hidrológicos.

El ajuste del modelo ARIMA a la serie muestra una línea recta con un valor de $116,78 \text{ hm}^3$ tanto para el periodo de entrenamiento como el periodo de validación, siendo este el mismo valor que la media de la serie. Los resultados obtenidos se muestran en la Figura 8.




Figura 8. Resultados del ajuste del modelo ARIMA $(0,0,0)$ a la serie histórica anual de Adaja. Se muestran los intervalos de confianza al 95%.

El valor de NSE obtenido es de $-0,13$, indicando un ajuste desfavorable del modelo.

Al ser una serie temporalmente independiente, el mejor ajuste se obtiene mediante un ARIMA $(0,0,0)$, con un ajuste igual a la media de la serie. En estos casos, donde el modelo es incapaz de detectar patrones claros y repetitivos en la serie, métodos de predicción simples, como la media móvil, suelen presentar un mayor rendimiento predictivo (Green y Armstrong, 2015).

Estos métodos basados en modelos clásicos paramétricos para el análisis de series temporales se caracterizan por tener una excesiva rigidez en la definición conceptual de sus hipótesis, lo que implica que no sean lo suficientemente flexibles y apropiados para modelizar y predecir parámetros hidrológicos como

la precipitación o el caudal en diferentes escalas temporales (Aguilera et al., 2019).

Se realizó un ajuste de varios modelos de Prophet a la serie temporal. El proceso de validación cruzada llevado a cabo para ajustar los hiperparámetros de los modelos de Prophet fue realizado empleando como periodo inicial el periodo de entrenamiento y un año vista como horizonte y periodo.

Similar a los resultados obtenidos con el modelo ARIMA (0,0,0), Prophet proporciona un ajuste y predicción en forma de línea recta con pendiente negativa, siendo incapaz también de detectar patrones en la serie. Los mejores resultados fueron obtenidos por el modelo Prophet_1. Estos resultados se detallan en la Figura 9.




Figura 9. Resultados del ajuste del modelo Prophet a la serie histórica anual de Adaja. Modelo Prophet_1. Se muestran los intervalos de confianza al 95%.

El valor de NSE obtenido es de -0,25, indicando un ajuste desfavorable del modelo.

Los problemas antes indicados se deben principalmente al hecho de ser un modelo aditivo. En este caso solo se está realizando un ajuste del modelo utilizando la componente $g(t)$, que representa la tendencia de la serie, al no contar con estacionalidad, serie anual, y tampoco emplearse la componente de vacaciones. Es por esto, por lo que no suele ser empleado en series anuales.

Por otro lado, la serie anual de Mijares analizada corresponde al periodo de 1946-2019 y cuenta con un total de 73 años hidrológicos. Nos encontramos ante una serie estacionaria, dado que el p valor obtenido del test ADF (Dickey y Fuller, 1979) es menor a 0,05, por lo que se rechaza la hipótesis nula (H_0). Los resultados del test se presentan en la Figura 10.

```
Augmented Dickey-Fuller Test:
ADF test statistic      -3.928854
p-value                0.001832
# lags used            1.000000
# observations         71.000000
critical value (1%)    -3.526005
critical value (5%)    -2.903200
critical value (10%)   -2.588995
Strong evidence against the null hypothesis
Reject the null hypothesis
Data has no unit root and is stationary
```

Figura 10. Resultados del test ADF para la serie anual de Mijares.

La media de la serie es de 26,40 hm³ y cuenta con asimetría positiva. Cabe destacar el periodo 1994-2018, donde los valores de aportaciones registradas se sitúan por debajo de la media, un comportamiento completamente diferente al inicio de la serie, donde se registran aportaciones abundantes, mayormente superiores a la media (Figura 11).

El primer valor obtenido fuera de los intervalos de confianza en las funciones de autocorrelación y autocorrelación corresponde a un desfase igual a un año, como se puede apreciar en la Figura 11. Los resultados de la función de autocorrelación indican que la serie cuenta con una dependencia temporal a dos años.

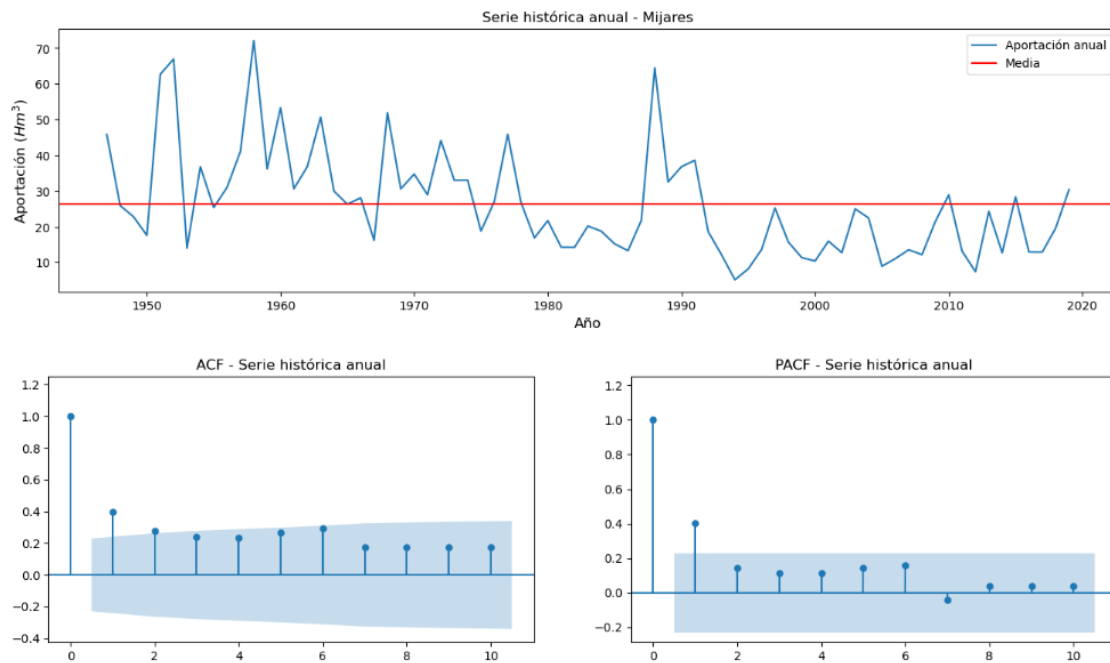


Figura 11. Serie histórica anual. Estación 8030 - Mijares. Intervalos de confianza al 95%. En la parte superior se muestra la serie histórica. En la parte inferior se muestran las funciones de autocorrelación (ACF) y autocorrelación parcial (PACF).

El valor del coeficiente de Hurst obtenido, 0,82, indica que la serie temporal presenta una autocorrelación positiva, con dependencia temporal. Esto se puede apreciar en el gráfico de la función de autocorrelación. Los resultados de los estadísticos de la serie se muestran en la Tabla 3.

Periodo	1946-2019, 73 años
Media	26,40 hm ³
Desviación estándar	14,92 hm ³
Coeficiente de variación	0,56
Coeficiente de asimetría	1,12
Exponente de Hurst	0,82

Tabla 3. Estadísticos de la serie histórica anual de Mijares.

Con estos resultados, fueron determinados los parámetros (p,d,q) de los modelos ARIMA a ajustar. El valor obtenido de la PACF se usa para estimar el parámetro q y el valor de la ACF para estimar el parámetro p del modelo ARIMA.

Por lo tanto, los valores óptimos para los parámetros p y q son 2 y 1, respectivamente.

Se ajustó el modelo ARIMA (1,0,1) a la serie, obteniéndose un mejor ajuste que con un ARIMA (2,0,1). Para la validación del modelo se empleó una amplitud del set de validación del cinco por ciento del total de valores de la serie, abarcando el periodo de 2015-2019, con 4 años hidrológicos. Los resultados obtenidos se muestran en la Figura 12.




Figura 12. Resultados del ajuste del modelo ARIMA (1,0,1) a la serie histórica anual de Mijares. Se muestran los intervalos de confianza al 95%.

El ajuste del modelo ARMA (1,0,1) obtuvo un valor del coeficiente NSE de -0,09, indicando un ajuste no óptimo del modelo a la serie.

Se realizaron ajustes del modelo con amplitudes mayores, pero los resultados obtenidos eran similares a los obtenidos para la serie de Adaja, el set de entrenamiento no contaba con dependencia temporal y el modelo más óptimo era un ARIMA (0,0,0). Los resultados obtenidos por este modelo proporcionaban un peor ajuste y una mayor incertidumbre en el set de validación.

Se realizó un ajuste de varios modelos de Prophet a la serie temporal. El proceso de validación cruzada desarrollado para justar los hiperparámetros de los modelos de Prophet fue realizado empleando como periodo inicial el periodo de entrenamiento y un año vista como horizonte y periodo, de manera similar al ajuste de la serie de Adaja.

El mejor ajuste a la serie anual se obtuvo con el modelo Prophet_2. El ajuste de este modelo a la serie temporal se caracteriza por tramos rectos con diferentes cambios de pendiente, correspondientes al número de puntos de cambios de tendencia definidos por el modelo. Los resultados obtenidos se muestran en la Figura 13.




Figura 13. Resultados del ajuste del modelo Prophet a la serie histórica anual de Mijares. Modelo Prophet_2. Se muestran los intervalos de confianza al 95%.

El ajuste del modelo en este caso, al igual que en la serie de Adaja, utiliza únicamente la componente $g(t)$, que representa la tendencia de la serie, al no contar con estacionalidad al ser una serie anual y tampoco emplearse la componente de vacaciones.

El valor de NSE obtenido, 0,07, para el modelo Prophet_2, corresponde a un ajuste deficiente del modelo a la serie.

Este ajuste deficiente se debe principalmente al emplear únicamente una componente del modelo, siendo incapaz de detectar patrones claros en la serie, ajustándose únicamente a la tendencia.

Los valores de NSE para los modelos ARIMA con mejor rendimiento ajustados a la serie de Adaja se encuentran en el rango de $[-0,13, -0,09]$, mientras que los modelos de Prophet con mejor rendimiento ajustados se encuentran en el rango de $[-0,26, -0,25]$. Para la serie de Mijares, estos se encuentran en el rango de $[-0,22, -0,09]$ y $[0,05, 0,07]$, respectivamente. El resto de los valores, se detallan en la Tabla 4.

Escala anual							
Serie	Modelo	MAE	RMSE	NSE	AIC	changepoint_prior_scale	changepoint_range
Adaja	ARIMA (0,0,0)	70,60	82,16	-0,13	629,57		
	ARIMA (0,0,1)	65,07	80,38	-0,09	630,46		
	ARIMA (1,0,0)	65,10	80,53	-0,09	630,49		
	Prophet_1	58,18	86,34	-0,25		0,001	0,85
	Prophet_2	58,19	86,35	-0,25		0,001	0,70
	Prophet_3	58,55	88,66	-0,26		0,005	0,90
Mijares	ARIMA (1,0,1)	6,96	7,46	-0,09	562,19		
	ARIMA (1,0,2)	7,20	7,82	-0,20	562,81		
	ARIMA (2,0,1)	7,29	7,91	-0,22	562,85		
	Prophet_1	6,26	6,93	0,06		5	0,90
	Prophet_2	5,99	6,90	0,07		5	0,85
	Prophet_3	6,30	6,97	0,05		10	0,70

Tabla 4. Resumen de resultados para la escala anual.

En la Tabla 4 también se detallan los valores de los hiperparámetros changepoint_prior_scale y changepoint_range ajustados en el modelo Prophet. Estos hiperparámetros han sido los únicos especificados en la escala anual, al carecer de estacionalidad.

En base a los modelos de mejor ajuste, se realizó una predicción a dos años vista para cada una de las series, obteniendo los siguientes resultados:

Serie	Modelo	2019 (hm ³)	2020 (hm ³)
Adaja	ARIMA (0,0,0)	116,78	116,78
	Prophet_1	63,77	62,42
Mijares	ARIMA (1,0,1)	21,42	21,67
	Prophet_2	20,92	21,30

Tabla 5. Predicciones anuales.

En ambas series, los valores obtenidos de ambos modelos para los años 2019 y 2020 son muy similares para un mismo modelo.

4.2 Escala mensual

La serie mensual de Adaja engloba un total de 924 meses. La media de la serie es de 9,73 hm³ y cuenta con una marcada asimetría positiva.

Nos encontramos ante una serie estacionaria, determinado mediante un test ADF (Dickey y Fuller, 1979), con un p valor menor a 0,05, rechazando la hipótesis nula (H_0). Los resultados obtenidos en el test se muestran en la Figura 14.

```
Augmented Dickey-Fuller Test:
ADF test statistic      -8.122292e+00
p-value                1.147450e-12
# lags used            9.000000e+00
# observations         9.140000e+02
critical value (1%)    -3.437525e+00
critical value (5%)    -2.864707e+00
critical value (10%)   -2.568457e+00
Strong evidence against the null hypothesis
Reject the null hypothesis
Data has no unit root and is stationary
```

Figura 14. Resultados del test ADF para la serie mensual de Adaja.

El periodo de 1980 a 2019 se caracteriza por unas aportaciones mensuales cercanas a la media en la mayor parte de los meses que componen el periodo. Por el contrario, el periodo de 1942 a 1980 presenta aportaciones mensuales muy por encima de la serie histórica, con escasos meses de sequía (Figura 15).

Fueron obtenidas las funciones de autocorrelación y autocorrelación parcial. En los resultados obtenidos de la función de autocorrelación se puede apreciar una cierta estacionalidad en la serie, con picos cada seis meses, aproximadamente. Esto indica la presencia de cierta periodicidad, con un periodo de seis meses, aproximadamente. En los resultados se aprecia un descenso a partir de un desfase igual a 2 meses, tanto para la ACF como la PACF. Por ello, se considera un valor de 2 como óptimo para los parámetros p y q , en una primera aproximación. Los resultados se muestran en la Figura 15.

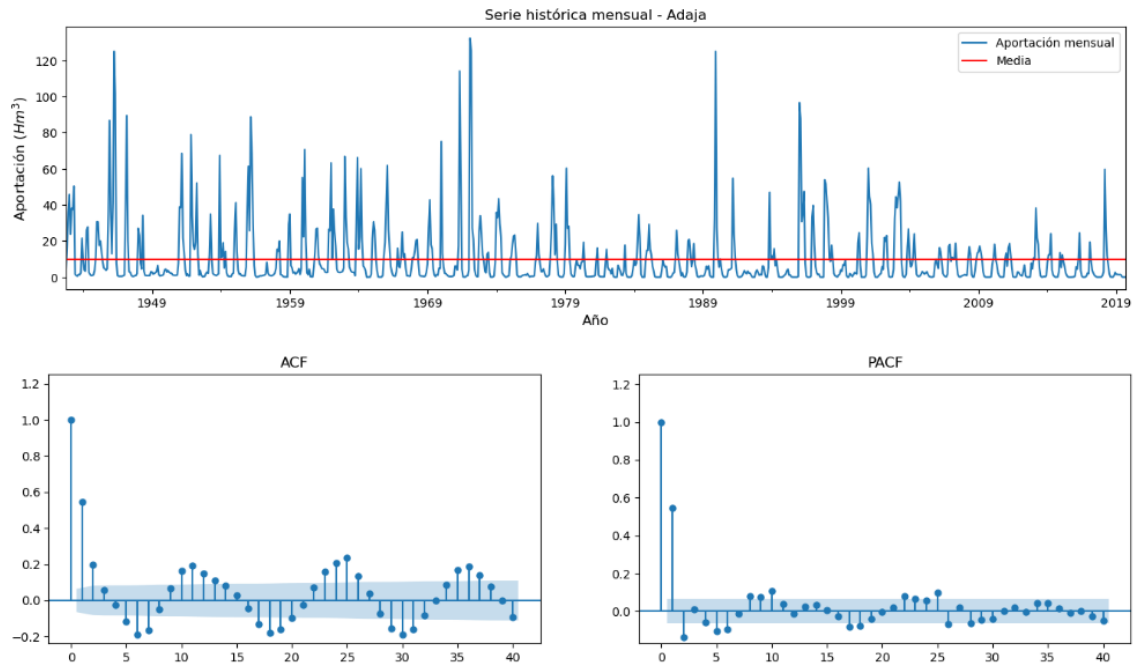


Figura 15. Serie histórica mensual. Estación 2046 - Adaja. Intervalos de confianza al 95%. En la parte superior se muestra la serie histórica. En la parte inferior se muestran las funciones de autocorrelación (ACF) y autocorrelación parcial (PACF).

Según valor del coeficiente de Hurst obtenido, 0,70, la serie cuenta con autocorrelación positiva a largo plazo, con dependencia temporal. Los valores de los estadísticos principales de la serie se muestran en la Tabla 6.

Periodo	1942-2019, 924 meses
Media	9,73 hm^3
Desviación estándar	17,03 hm^3
Coeficiente de variación	1,75
Coeficiente de asimetría	3,38
Exponente de Hurst	0,70

Tabla 6. Estadísticos de la serie histórica mensual de Adaja.

Para el ajuste de los modelos, se ha empleado una amplitud del set de validación del dieciocho por ciento de los valores de la serie, con un total de 167 meses. Se realizaron pruebas con diferentes amplitudes, siendo esta la que garantizaba el mejor ajuste de los modelos.

Para el ajuste de la serie mensual, se ha empleado un modelo SARIMA $(2,0,2)(1,0,1)[6]$. El modelo no es capaz de predecir los picos que se registran en la serie, ni los años de sequía. Los resultados obtenidos se muestran en la Figura 16.




Figura 16. Resultados del ajuste del modelo SARIMA $(2,0,2)(1,0,1)[6]$ a la serie histórica mensual de Adaja. Se muestran los intervalos de confianza al 95%.

En la Figura 17 se puede apreciar como el modelo es incapaz de capturar los picos que se producen en el 2013 y en el 2018.




Figura 17. Resultados del ajuste del modelo SARIMA $(2,0,2)(1,0,1)[6]$ a la serie histórica mensual de Adaja. Periodo de validación.

El valor de NSE obtenido para el ajuste del modelo SARIMA a la serie temporal es de 0,20, considerándose no óptimo.

De manera similar a las series anuales, se realizaron ajustes de varios modelos de Prophet a la serie temporal. El proceso de validación cruzada fue realizado empleando como periodo inicial el periodo de entrenamiento, cinco años de horizonte y cinco años de periodo. Se ha considerado una estacionalidad multiplicativa.

El modelo de mejor ajuste a la serie es el denominado Prophet_1. Este modelo consigue un buen ajuste de la periodicidad presente, empleando una serie de Fourier de séptimo orden. Se realizaron también pruebas empleando una serie de Fourier de sexto orden, obteniendo peores resultados. Los resultados de este modelo se muestran en la Figura 18.




Figura 18. Resultados del ajuste del modelo Prophet a la serie histórica mensual de Adaja. Modelo Prophet_1. Se muestran los intervalos de confianza al 95%.

El valor de NSE obtenido por el modelo Prophet_1, es de 0,04, siendo desfavorable el ajuste del modelo a la serie temporal.

Sin embargo, en los valores de aportaciones del periodo de validación se pueden apreciar varios años en los que la época de lluvias se concentra en menos meses, con eventos más extremos, siendo imposible para el modelo ajustarse de manera correcta a estos casos (Figura 19). Esto puede apreciar en el gráfico de la función de autocorrelación (Figura 15), donde se producen picos en los desfases 6,11 y 18, lo que determina la presencia de un comportamiento casi periódico en la serie, sin presencia de estacionalidad, al ser la serie estacionaria (Figura 14).




Figura 19. Resultados del ajuste del modelo Prophet a la serie histórica mensual de Adaja. Modelo Prophet_1. Periodo de validación.

Esto se debe a que en el modelo de Prophet, las componentes estacionales y las vacaciones son funciones periódicas constantes, es decir, no cambian con el tiempo. En este caso, el modelo cuenta con una estacionalidad mensual ajustada mediante una serie de Fourier de séptimo orden, como se detalla en proceso de ajuste. Este es uno de los puntos débiles del modelo (Aguilera et al., 2019).

También se pueden apreciar dos años con aportaciones relativamente escasas, como son el 2012 y 2019. En ambos casos, los valores obtenidos por el modelo son similares a las aportaciones obtenidas para el resto de años, sin variar significativamente.

La serie mensual de Mijares engloba un total de 876 meses. La media de la serie es de 2,2 hm³ y cuenta con una marcada asimetría positiva.

Nos encontramos ante una serie estacionaria, determinado mediante un test ADF (Dickey y Fuller, 1979), con un p valor inferior a 0,05, rechazamos la hipótesis nula (H_0). Los resultados obtenidos del test se muestran en la Figura 20.


```
Augmented Dickey-Fuller Test:
ADF test statistic      -9.052808e+00
p-value                4.789065e-15
# lags used            4.000000e+00
# observations         8.710000e+02
critical value (1%)    -3.437880e+00
critical value (5%)    -2.864864e+00
critical value (10%)   -2.568540e+00
Strong evidence against the null hypothesis
Reject the null hypothesis
Data has no unit root and is stationary
```

Figura 20. Resultados del test ADF para la serie mensual de Mijares.

La serie se caracteriza por aportaciones cercanas a la media en el periodo de 1993-2019, contando el resto de la serie con aportaciones superiores a la media. Comportamiento similar a la serie mensual de Adaja.

Fueron obtenidas las funciones de autocorrelación y autocorrelación parcial (Figura 21). En los resultados no se aprecia la presencia de estacionalidad en la serie temporal, siendo una serie estacionaria. Por ello, se ha decidido por ajustar un modelo ARIMA a la serie temporal, en vez de un SARIMA, como en el caso de Adaja.

En la ACF se aprecia un descenso de los valores a partir de un desfase igual a 6 meses, situándose los valores posteriores dentro de los intervalos de confianza. En la PACF se aprecia un descenso a partir de un valor de desfase igual a 2 meses.

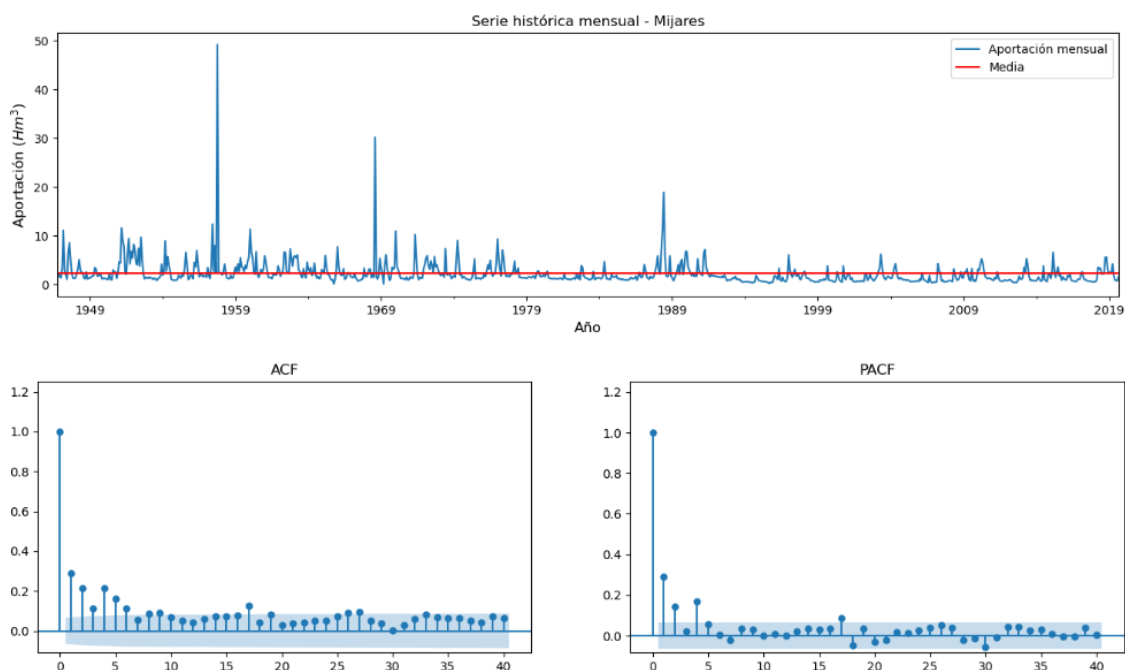


Figura 21. Serie histórica mensual. Estación 8030 - Mijares. Intervalos de confianza al 95%. En la parte superior se muestra la serie histórica. En la parte inferior se muestran las funciones de autocorrelación (ACF) y autocorrelación parcial (PACF).

Según valor del coeficiente de Hurst obtenido, 0,76, la serie cuenta con autocorrelación positiva y dependencia temporal, pudiéndose apreciar también en el gráfico de la función de autocorrelación. En la Tabla 7 se muestran los resultados de los estadísticos principales de la serie.

Periodo	1946-2019, 876 meses
Media	2,20 hm^3
Desviación estándar	2,63 hm^3
Coeficiente de variación	1,19
Coeficiente de asimetría	8,71
Exponente de Hurst	0,76

Tabla 7. Estadísticos de la serie histórica mensual de Mijares.

Para el ajuste de los modelos, se ha empleado una amplitud del set de validación de un tercio de la serie, con un total de 263 meses. Se realizaron pruebas con diferentes amplitudes, en todos los casos analizados se obtuvieron resultados similares.

Para el ajuste de la serie mensual, se ha empleado un modelo ARIMA (5,0,0). Los resultados obtenidos se muestran en la Figura 22.




Figura 22. Resultados del ajuste del modelo ARIMA (5,0,0) a la serie histórica mensual de Mijares. Se muestran los intervalos de confianza al 95%.

El modelo ARIMA (5,0,0) presenta un ajuste que tiende a estabilizarse al valor de la media de la serie histórica, al ser incapaz de encontrar patrones claros en la serie (Figura 23). Comportamientos similares son mostrados en los diferentes modelos ajustados a la serie. El valor de NSE obtenido es de -0,48, considerándose no óptimo.




Figura 23. Resultados del ajuste del modelo ARIMA (5,0,0) a la serie histórica mensual de Mijares. Periodo de validación.

De manera similar a las series anuales, se realizaron ajustes de varios modelos de Prophet a la serie temporal. El proceso de validación cruzada fue realizado empleando como periodo inicial el periodo de entrenamiento, cinco años de horizonte y cinco años de periodo.

El mejor ajuste a la serie se obtuvo con el modelo Prophet_2. En este caso, al no contar con la presencia de estacionalidad, fueron ajustados el mismo conjunto de hiperparámetros que en el caso de las series anuales. Los resultados obtenidos se muestran en la Figura 24.




Figura 24. Resultados del ajuste del modelo Prophet_2 a la serie histórica mensual de Mijares. Se muestran los intervalos de confianza al 95%.

El modelo es incapaz de detectar patrones en la serie y, por lo tanto, las predicciones ofrecidas no son óptimas (Figura 25). Al carecer de una componente autorregresiva, el ajuste a una serie temporal con las características de la serie empleada resulta complejo.




Figura 25. Resultados del ajuste del modelo Prophet_2 a la serie histórica mensual de Mijares. Periodo de validación.

El valor de NSE obtenido por el modelo Prophet_2 es de -0,92, siendo desfavorable el ajuste del modelo a la serie temporal.

Los valores de NSE para los modelos SARIMA con mejor rendimiento, ajustados a la serie de Adaja se encuentran en el rango de [0,01, 0,20], mientras que los modelos de Prophet con mejor rendimiento ajustados se encuentran en el rango de [0,01, 0,04]. Para la serie de Mijares, estos se encuentran en el rango de [-0,48,-0,49] y [-1,43, -0,92], respectivamente. El resto de los valores, se detallan en la Tabla 8.

Escala mensual							
Serie	Modelo	MAE	RMSE	NSE	AIC	changepoint prior_scale	changepoi nt_range
Adaja	SARIMA (2,0,2)(1,0,1)[6]	4,38	7,03	0,20	6271,52		
	SARIMA (2,0,2)(1,0,0)[6]	5,96	7,93	0	6276,81		
	SARIMA (2,0,2)(0,0,1)[6]	5,97	7,94	0	6277,31		
	Prophet_1	5,11	7,75	0,04		0,015	0,75
	Prophet_2	5,22	7,88	0,01		0,015	0,80
	Prophet_3	5,22	7,87	0,01		0,015	0,85
Mijares	ARIMA (4,0,0)	1,22	1,37	-0,49	3037,85		
	ARIMA (5,0,0)	1,21	1,37	-0,48	3038,07		
	ARIMA (4,0,1)	1,21	1,37	-0,48	3038,34		
	Prophet_1	1,32	1,75	-1,43		0,50	0,80
	Prophet_2	1,16	1,56	-0,92		0,10	0,70
	Prophet_3	1,21	1,62	-1,08		0,10	0,80

Tabla 8. Coeficientes de ajuste obtenidos para los modelos mensuales.

Empleando los modelos de mejor ajuste, se realizaron predicciones a dos años vista. Los resultados obtenidos son los siguientes:

Predicción (hm ³)				
Serie	Adaja		Mijares	
Mes	SARIMA (2,0,2)(1,0,1)[6]	Prophet_1	ARIMA (5,0,0)	Prophet_2
10/2019	0,62	0	1,66	0,38
11/2019	2,79	0	1,73	1,18
12/2019	10,16	2,40	1,72	0,56
01/2020	13,57	8,63	1,85	0,75
02/2020	14,03	12,21	1,95	1,27
03/2020	14,90	16,03	2,00	1,06
04/2020	12,73	13,22	2,03	1,21
05/2020	9,60	11,57	2,06	1,02
06/2020	2,00	9,37	2,10	1,71
07/2020	0	0,57	2,11	1,82
08/2020	0	0	2,13	0,60
09/2020	0	0	2,14	1,10
10/2020	0	0	2,15	0,13
11/2020	2,46	0	2,16	1,18
12/2020	10,06	2,26	2,17	0,50
01/2021	13,54	8,31	2,17	0,75
02/2021	14,01	11,99	2,18	1,31
03/2021	14,87	16,02	2,18	1,00
04/2021	12,70	14,4	2,18	1,22
05/2021	9,58	11,94	2,19	1,04
06/2021	1,98	10,34	2,19	1,68
07/2021	0	0,95	2,19	1,73
08/2021	0	0	2,19	0,57
09/2021	0	0	2,19	1,04

Tabla 9. Predicciones mensuales.

Para la serie de Adaja, las predicciones de los modelos indican aportaciones nulas para los meses de julio a octubre, según el modelo SARIMA y de agosto a noviembre según el modelo Prophet. Ambos modelos arrojan predicciones de magnitudes similares, siendo el mayor valor 14,87 hm³ para el modelo SARIMA y 16,02 hm³ en el caso de Prophet.

En la serie histórica de Mijares, las predicciones del modelo ARIMA (5,0,0) son cercanas a la media de la serie. Por el contrario, las predicciones obtenidas mediante Prophet son valores inferiores a la media, situándose en un rango de 0,3-1,8 hm³.

5 Aplicabilidad de los modelos

Las predicciones obtenidas a partir de los modelos pueden ser empleadas para labores de planificación hidrológica, previendo posibles escenarios de sequía.

Los escenarios de escasez o sequía hidrológica implican problemas para satisfacer las diferentes demandas. Generalmente, se presentan de manera diferida en el tiempo respecto a los episodios de sequía meteorológica. Estos escenarios pueden incluso no llegar a producirse, o minimizarse mediante una adecuada gestión de los recursos, o por la no existencia de demandas importantes.

La anticipación a los posibles problemas con respecto a las demandas permite identificar mediante los indicadores de escasez contemplados en los Planes Especiales de Sequía (PES), para las diferentes Unidades Territoriales de Escasez (UTE), cuatro escenarios. Se contemplan los escenarios de normalidad, prealerta, alerta y emergencia. Estos escenarios representan las expectativas respecto a la atención de las demandas existentes en los meses venideros. El objetivo principal es la implementación progresiva de las medidas definidas en los PES evitando el avance hacia escenarios severos de escasez y del mismo modo, mitigar sus impactos negativos.

A continuación, se detallan las relaciones entre los recursos disponibles, obtenidos a partir de los modelos, y las diferentes demandas a las que deben hacer frente para los casos de estudio escogidos.

5.1 Adaja

La estación 2046 de Adaja se encuentra dentro de la Unidad Territorial de Escasez de Adaja, definida en el PES de la confederación hidrográfica del Duero. Esta UTE cuenta con dos embalses, siendo el mayor, el denominado embalse de Las Cogotas, aguas abajo de la estación estudiada. El agua del embalse de Las Cogotas se destina a los usos de navegación, control de avenidas, abastecimiento, regadío y producción energética.

Esta UTE cuenta con una superficie de 2.365 km² con unos recursos de 145,7 hm³ de origen natural, según la media anual de la serie 1980/81-2005/06.

En la siguiente tabla se detallan las demandas de agua por cada uno de los usos contemplados en la UTE de Adaja y la procedencia del recurso.

Uso	Origen superficial		Origen subterráneo (hm ³ /año)	Demanda total (hm ³ /año)
	Reguladas (hm ³ /año)	No reguladas (hm ³ /año)		
Urbano	9,06	0,40	1,99	11,44
Regadío	32,07	4,64	32,17	68,88
Ganadero			4,10	4,10
Industrial	0,11			0,11
Otros usos			0,33	0,30
Total	41,24	5,04	38,59	84,87

Tabla 10. Origen de los recursos en la UTE 10.3 - Adaja. Fuente: Plan Especial de Sequía (2018).

Por otro lado, se han contemplado también los caudales ecológicos del tramo del embalse de Las Cogotas en la demanda de recursos, detallados en la siguiente tabla:

Mes	Oct	Nov	Dic	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Total anual (hm ³)
Demanda ecológica (hm³)	0,86	0,83	0,96	1,37	1,28	1,42	1,53	1,34	0,83	0,86	0,86	0,83	12,96

Tabla 11. Demanda ecológica para el tramo del embalse Las Cogotas. Fuente: Plan Especial de Sequía (2018).

La demanda anual total asciende a 84,87 hm³ en esta UTE, considerando la demanda ecológica del tramo de río, tendríamos una demanda total de 97,80 hm³. Las predicciones obtenidas a escala mensual por los modelos indican un porcentaje de demanda satisfecha del 74% y 82,21%, según las aportaciones de los modelos SARIMA y Prophet, respectivamente, para el año 2019. Para el año 2020, este porcentaje se encuentra en el 76,21% y 80,98%, respectivamente. Las aportaciones de origen superficial serían capaces de satisfacer la demanda anual a excepción de los meses del periodo estival.




Figura 26. Evolución de las aportaciones y demanda acumuladas para la UTE de Adaja, año 2019.




Figura 27. Evolución de las aportaciones y demanda acumuladas para la UTE de Adaja, año 2020.

Hay que tener en cuenta, que las demandas de esta UTE, según la información expuesta en el PES vigente, se satisfacen en un 50% por ciento por recursos superficiales y el otro 50% a partir de recursos de origen subterráneo. Bajo esta hipótesis, se dispondría con un porcentaje del 25-30% de la aportación anual registrada por la estación que sería almacenada en el embalse y estaría disponible para futuras demandas.

En el caso de las aportaciones obtenidas de la escala anual, los porcentajes de demanda satisfecha se encuentran en el 116% y 63%, para el modelo ARIMA y Prophet, respectivamente.

5.2 Mijares

La estación 8030 de Mijares se encuentra dentro de la Unidad Territorial de Escasez de Mijares-Plana de Castellón, definida en el PES de la confederación hidrográfica del Júcar. Esta UTE comprende las cuencas de los ríos Mijares, Seco, Veo y Belcaire y las subcuencas litorales comprendidas entre Benicasim y el límite provincial entre Castellón y Valencia.

La UTE cuenta con tres embalses principales, Arenós, Sicha y María Cristina. La estación se encuentra ubicada en el tramo del río Mirajes que alimenta el embalse de Arenós, el cual cuenta con una capacidad máxima de 136,9 hm³ y se dedica principalmente a satisfacer la demanda agraria. La superficie regada en la UTE es de 33.594 ha. Las aportaciones anuales medias registradas en la UTE son de 429,6 hm³.

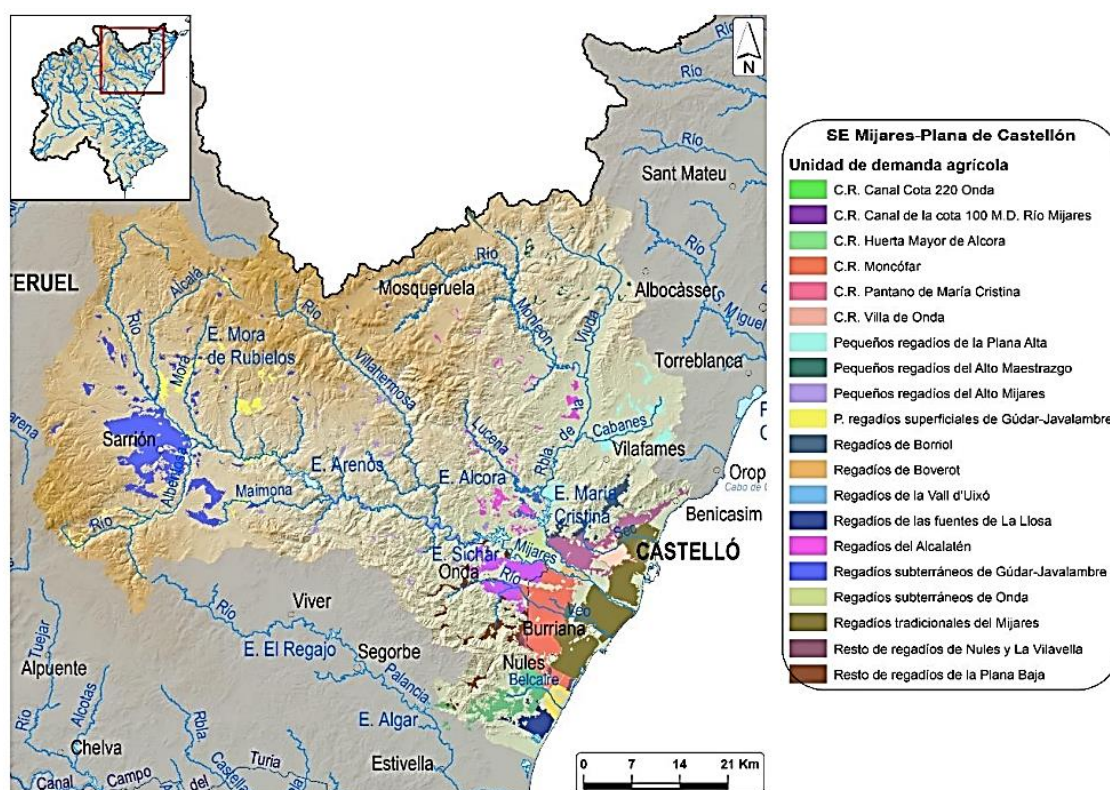


Figura 28. Superficie regada en la UTE de Mijares-Plana de Castellón. Fuente: Plan Especial de Sequía (2018).

La demanda agraria anual de la UTE se detalla a continuación:

Mes	Oct	Nov	Dic	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Total anual (hm ³)
Demanda ecológica (hm³)	9,40	4,50	3,60	3,20	3,60	5,30	12,70	21,60	33,90	40,40	27,40	16,40	182,00

Tabla 12. Demanda agraria para la UTE de Mijares-Plana de Castellón. Fuente: Plan Hidrológico (2022).

Por otro lado, se ha contemplado también la demanda ecológica del tramo del embalse de Arenós en la demanda de recursos, detallada en la siguiente tabla:

Mes	Oct	Nov	Dic	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Total anual (hm ³)
Demanda ecológica (hm³)	2,95	2,85	3,32	3,32	3,36	3,72	3,99	3,72	3,21	2,95	2,95	2,85	39,20

Tabla 13. Demanda ecológica para el tramo del embalse de Arenós. Fuente: Plan Especial de Sequía (2018).

La demanda anual total asciende a 221,20 hm³, considerando la demanda ecológica del tramo de estudio. Las predicciones obtenidas a escala mensual por los modelos indican un porcentaje de demanda satisfecha del 23,48% y 12,66%, según las aportaciones de los modelos ARIMA y Prophet, respectivamente, para el año 2019. Para el año 2020, este porcentaje se encuentra en el 26,14% y 12,15%, respectivamente.

Aportaciones vs Demanda (2019)




Figura 29. Evolución de las aportaciones y demanda acumuladas para la UTE de Mijares-Plana de Castellón, año 2019.




Figura 30. Evolución de las aportaciones y demanda acumuladas para la UTE de Mijares-Plana de Castellón, año 2020.

El resto de la demanda deberá de ser satisfecha mediante recursos de origen subterráneo, que en la UTE ascienden a los 72,92 hm³/año, y mediante otras aportaciones de origen superficial.

6 Conclusiones y futuras líneas de trabajo

Según los resultados obtenidos, dado el objetivo principal de evaluar el rendimiento y la capacidad predictiva en cuencas hidrográficas en régimen natural del algoritmo Prophet, se observa que el rendimiento obtenido por el modelo, en los diferentes casos analizados, lo sitúa del lado de los modelos clásicos. Esto es debido a que su rendimiento no difiere significativamente respecto a los enfoques ARIMA propuestos.

Prophet, destaca por su buen rendimiento en aquellos casos en los que esté presente una clara estacionalidad, no siendo recomendable su uso en series temporales independientes y sin una marcada estacionalidad. Prophet, al contrario de los modelos autorregresivos, no tiene en cuenta la correlación temporal de los datos. Esto, a pesar de ser una de sus principales ventajas, ya que le permite tratar con valores nulos o intervalos irregulares de muestreo, puede dar lugar a situaciones en las que no es capaz de predecir eventos de diferente magnitud, respecto a la serie histórica. Es el caso de la serie mensual de Adaja, donde el modelo Prophet_1, empleando una serie de Fourier de séptimo orden, no es capaz de predecir los meses con elevadas aportaciones y/o periodos de sequía presentes en la serie.

Con el procesado y segmentación de series temporales hidrológicas con diferente comportamiento temporal, se ha puesto de manifiesto la ineficiencia del modelo para su empleo en series temporales anuales con un comportamiento temporal independiente. En estos casos, el ajuste del modelo se realiza mediante la componente $g(t)$, que representa la tendencia de la serie, al no contar con estacionalidad ni el efecto de vacaciones.

Mediante el ajuste de los enfoques ARIMA contemplados se demuestra que, a pesar de ser ampliamente utilizados en diferentes ámbitos, en los casos de estudio analizados no son lo suficientemente flexibles y adecuados para modelizar procesos hidrológicos estocásticos como las series de aportaciones anuales y mensuales.

Mediante la evaluación de su rendimiento en series a escala mensual, se ha puesto de manifiesto la incapacidad de Prophet de simular la estacionalidad como una función variable en el tiempo. Esto da lugar a ajustes no favorables a casos de estudio reales, como la serie mensual de Adaja, donde los periodos varían con el tiempo, algo cada vez más frecuente en el contexto de cambio climático en el que nos encontramos.

A partir de estos resultados, como futura nueva línea de trabajo se contempla la evaluación del rendimiento de Prophet empleando series temporales de precipitaciones de manera conjunta a la serie de aportaciones. Del mismo modo, se propone realizar un primer análisis conjunto del rendimiento del modelo NeuralProphet, la versión de redes neuronales de Prophet, en el ámbito de la hidrología. De esta manera, haciendo énfasis en las diferencias entre ambos modelos, se obtendría la relación de ventajas y deficiencias del uso de esta versión de redes neuronales frente al enfoque propuesto en este trabajo.

7 Bibliografía

- Aguilera, H., Guardiola-Albert, C., Naranjo-Fernández, N., y Kohfahl, C. (2019). Towards flexible groundwater-level prediction for adaptive water management: using Facebook's Prophet forecasting approach. *Hydrological Sciences Journal*, 64(12), 1504-1518. <https://doi.org/10.1080/02626667.2019.1651933>
- Aditya Satrio, C. B., Darmawan, W., Nadia, B. U., y Hanafiah, N. (2021). Time series analysis and forecasting of coronavirus disease in Indonesia using ARIMA model and PROPHET. *Procedia Computer Science*, 179, 524–532. <https://doi.org/10.1016/j.procs.2021.01.036>
- Aziz, M. I. A., Barawi, M. H., y Shahiri, H. (2022). Is Facebook PROPHET Superior than Hybrid ARIMA Model to Forecast Crude Oil Price? *Sains Malaysiana*, 51(8), 2633–2643. <https://doi.org/10.17576/jsm-2022-5108-22>
- Akaike, H. (1973). *Information theory and an extension of the maximum likelihood principle*. Akademiai Kiado.
- Anaconda. (2023). Anaconda Distribution. Recuperado el 5 de febrero de 2023, de <https://www.anaconda.com/products/distribution>.
- Basak, A., Rahman, A. T. M. S., Das, J., Hosono, T., y Kisi, O. (2022). Drought forecasting using the Prophet model in a semi-arid climate region of western India. *Hydrological Sciences Journal*, 67(9), 1397-1417. <https://doi.org/10.1080/02626667.2022.2082876>
- Benzvi, M., y Kedem, B. (1977). ARIMA models for hydrological time-series. *Advances in Applied Probability*, 9(2), 231. <https://doi.org/10.1017/S000186780004386X>
- Berrar, D. (2018). Cross-validation. En *Encyclopedia of Bioinformatics and Computational Biology: ABC of Bioinformatics* (Vols. 1-3, pp. 542-545). Elsevier. <https://doi.org/10.1016/B978-0-12-809633-8.20349-X>
- Box, G., y Jenkins, G. (1970). *Time Series Analysis: Forecasting and Control* (2.^a ed.). Holden-Day.

CEDEX. (2023). Anuario de aforos, datos de la estación 2046-Adaja. Recuperado el 2 de febrero de 2023, de https://ceh.cedex.es/anuarioaforos/afo/estaf-datos_descarga.asp?indroea=2046.

CEDEX. (2023). Anuario de aforos, datos de la estación 8030-Mijares. Recuperado el 2 de febrero de 2023, de https://ceh.cedex.es/anuarioaforos/afo/estaf-datos_descarga.asp?indroea=8030.

Chai, T., y Draxler, R. R. (2014). Root mean square error (RMSE) or mean absolute error (MAE)? -Arguments against avoiding RMSE in the literature. *Geoscientific Model Development*, 7(3), 1247-1250. <https://doi.org/10.5194/gmd-7-1247-2014>

Chapman, A. R., Kerr, B., y Wilford, D. (2018). A water allocation decision-support model and tool for predictions in ungauged basins in northeast British Columbia, Canada. *Journal of The American Water Resources Association*, 54(3), 676-693. <https://doi.org/10.1111/1752-1688.12643>

Charilaou, P., y Battat, R. (2022). Machine learning models and over-fitting considerations. *World Journal of Gastroenterology*, 28(5), 605-607. <https://doi.org/10.3748/wjg.v28.i5.605>

Chaturvedi, S., Rajasekar, E., Natarajan, S., y McCullen, N. (2022). A comparative assessment of SARIMA, LSTM RNN and Fb Prophet models to forecast total and peak monthly energy demand for India. *Energy Policy*, 168. <https://doi.org/10.1016/j.enpol.2022.113097>

Confederación hidrográfica del Júcar. (2023). Presentación de la cuenca. Recuperado el 5 de abril de 2023, de <https://www.chj.es/es-es/medioambiente/cuencahidrografica/Paginas/Presentaci%C3%B3ndelacuenca.aspx>.

Criss, R. E., y Winston, W. E. (2008). Do Nash values have value? Discussion and alternate proposals. *Hydrological Processes*, 22(14), 2723-2725. <https://doi.org/10.1002/hyp.7072>

- Cross Validation (2023). Scikit-learn. Recuperado el 10 de abril de 2023, de https://scikit-learn.org/stable/modules/cross_validation.html.
- Dastorani, M., Mirzavand, M., Dastorani, M. T., y Sadatinejad, S. J. (2016). Comparative study among different time series models applied to monthly rainfall forecasting in semi-arid climate condition. *Natural Hazards*, 81(3), 1811-1827. <https://doi.org/10.1007/s11069-016-2163-x>
- Dickey, D. A., y Fuller, W. A. (1979). Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, 74(366), 427. <https://doi.org/10.2307/2286348>
- Djebou, D. C. S., y Singh, V. P. (2016). Impact of climate change on precipitation patterns: a comparative approach. *International Journal of Climatology*, 36(10), 3588-3606. <https://doi.org/10.1002/joc.4578>
- Donat, M. G., Lowry, A. L., Alexander, L. V, O’Gorman, P. A., y Maher, N. (2016). More extreme precipitation in the world’s dry and wet regions. *Nature Climate Change*, 6(5), 508-513. <https://doi.org/10.1038/nclimate2941>
- Efron, B. (1979). Bootstrap Methods: Another look at the jackknife. *The Annals of Statistics*, 7(1), 1 – 26. <https://doi.org/10.1214/aos/1176344552>
- Estrela, T., Pérez-Martin, M. A., y Vargas, E. (2012). Impacts du changement climatique sur les ressources en eau en Espagne. *Hydrological Sciences Journal*, 57(6), 1154-1167. <https://doi.org/10.1080/02626667.2012.702213>
- Garijo, C., y Mediero, L. (2019). Assessment of changes in annual maximum precipitations in the Iberian Peninsula under climate change. *Water (Switzerland)*, 11(11). <https://doi.org/10.3390/w11112375>
- Green, K. C., y Armstrong, J. S. (2015). Simple versus complex forecasting: The evidence. *Journal of Business Research*, 68(8), 1678-1685. <https://doi.org/https://doi.org/10.1016/j.ibusres.2015.03.026>
- Gurnell, A. M., Clark, M. J., y Hill, C. T. (1992). Analysis and interpretation of patterns within and between hydroclimatological time series in an alpine glacier basin. En *Earth Surface Processes And Landforms* (Vol. 17).

- Hossain, M. M., Faisal Anwar, A. H. M., Garg, N., Prakash, M., y Bari, M. (2022). Monthly rainfall prediction at catchment level with the Facebook Prophet model using observed and CMIP5 decadal Data. *Hydrology*, 9(6). <https://doi.org/10.3390/hydrology9060111>
- Hydrostats. (2023). Hydrostats documentation. Recuperado el 5 de febrero de 2023, de <https://hydrostats.readthedocs.io/en/latest/>.
- Jimenez-Donaire, M. del P., Giraldez, J. V., y Vanwalleghem, T. (2020). Impact of climate change on agricultural droughts in Spain. *WATER*, 12(11). <https://doi.org/10.3390/w12113214>
- Kendall, D. R., y Dracup, J. A. (1991). A comparison of index-sequential and AR(1) generated hydrologic sequences. *Journal of Hydrology*, 122(1-4), 335-352. [https://doi.org/10.1016/0022-1694\(91\)90187-M](https://doi.org/10.1016/0022-1694(91)90187-M)
- Khan, M. M. H., Muhammad, N. S., y El-Shafie, A. (2020). Wavelet based hybrid ANN-ARIMA models for meteorological drought forecasting. *Journal of Hydrology*, 590. <https://doi.org/10.1016/j.jhydrol.2020.125380>
- Khatibi, R., Ghorbani, M. A., Naghipour, L., Jothiprakash, V., Fathima, T. A., y Fazelifard, M. H. (2014). Inter-comparison of time series models of lake levels predicted by several modeling strategies. *Journal of Hydrology*, 511, 530-545. <https://doi.org/10.1016/j.jhydrol.2014.01.009>
- Koutsoyiannis, D. (2004). Hydrologic persistence and the Hurst phenomenon. En *Water Encyclopedia* (pp. 210-221). Wiley. <https://doi.org/10.1002/047147844x.sw434>
- Lee, T., y Ouarda, T. B. M. J. (2011). Identification of model order and number of neighbors for k-nearest neighbor resampling. *Journal of Hydrology*, 404(3-4), 136-145. <https://doi.org/10.1016/j.jhydrol.2011.04.024>
- Little, M. A., Varoquaux, G., Saeb, S., Lonini, L., Jayaraman, A., Mohr, D. C., y Kording, K. P. (2017). Using and understanding cross-validation strategies Perspectives on Saeb et al. *Gigascience*, 6(5). <https://doi.org/10.1093/gigascience/gix020>

- Lorenzo, M. N., y Alvarez, I. (2022). Future changes of hot extremes in Spain: towards warmer conditions. *Natural Hazards*, 113(1), 383-402.
<https://doi.org/10.1007/s11069-022-05306-x>
- Mccuen, R. H., Knight, Z., y Cutter, A. G. (2006). Evaluation of the Nash-Sutcliffe efficiency index. *Journal of Hydrologic Engineering*, 11(6), 597-602.
<https://doi.org/10.1061/ASCE1084-0699200611:6597>
- Mesa, O. J., y Poveda, G. (1993). The Hurst effect: the scale of fluctuation approach. En *Water Resources Research* (Vol. 29, Número 12).
- Meta. (2023). Prophet forecasting at scale. Recuperado el 5 de febrero de 2023, de <https://facebook.github.io/prophet/>.
- Mingarro López, M., Prieto, F., Estévez Estévez, R., y Alfonso, C. (2021). *Informe aproximación a la evolución de las precipitaciones en España*.
- Ministerio para la Transición Ecológica y el Reto Demográfico (2018). Plan especial de Sequía CHD, Memoria. Confederación hidrográfica del Duero.
- Ministerio para la Transición Ecológica y el Reto Demográfico (2018). Plan especial de Sequía CHJ, Memoria. Confederación hidrográfica del Júcar.
- Ministerio para la Transición Ecológica y el Reto Demográfico. (2022). Plan Hidrológico de la parte española de la Demarcación Hidrográfica del Duero, revisión de tercer ciclo (2022-2027). Confederación hidrográfica del Duero.
- Ministerio para la Transición Ecológica y el Reto Demográfico. (2022). Plan Hidrológico de la Demarcación Hidrográfica del Júcar, revisión de tercer ciclo (2022-2027). Confederación hidrográfica del Júcar.
- MLflow. (2023). MLflow stable 2.0. Recuperado el 5 de febrero de 2023, de <https://mlflow.org/>.
- Modarres, R. (2007). Streamflow drought time series forecasting. *Stochastic Environmental Research and Risk Assessment*, 21(3), 223-233.
<https://doi.org/10.1007/s00477-006-0058-1>

- Molina, J.-L., y Zazo, S. (2018). Assessment of temporally conditioned runoff fractions in unregulated rivers. *Journal of Hydrologic Engineering*, 23(5). [https://doi.org/10.1061/\(asce\)he.1943-5584.0001645](https://doi.org/10.1061/(asce)he.1943-5584.0001645)
- Molina, J. L., Zazo, S., y Martín, A. M. (2019). Causal reasoning: Towards dynamic predictive models for runoff temporal behavior of high dependence rivers. *Water (Switzerland)*, 11(5). <https://doi.org/10.3390/w11050877>
- Moriasi, D. N., Arnold, J. G., Liew, M. W. Van, Bingner, R. L., Harmel, R. D., y Veith, T. L. (1983). Model evaluation guidelines for systematic quantification of accuracy in watershed simulations. En *Transactions of the ASABE* (Vol. 50, Número 3).
- Nash, J. E., y Sutcliffe, J. V. (1970). River flow forecasting through conceptual models. Part I - A discussion of principles. En *Journal of Hydrology* (Vol. 10). © North-Holland Publishing Co.
- Navratil, M., y Kolkova, A. (2019). Decomposition and forecasting time series in business economy using prophet forecasting model. *Central European Business Review*, 8(4), 26–39. <https://doi.org/10.18267/j.cebr.221>
- Nozari, H., y Tavakoli, F. (2020). Forecasting hydrologic parameters using linear and nonlinear stochastic models. *Journal of Water and Climate Change*, 11(4), 1284-1301. <https://doi.org/10.2166/wcc.2019.249>
- Nurhayati, Hadihardaja, I. K., Soekarno, I., y Cahyono, M. (2014). A study of Hold-Out and K-Fold Cross Validation for accuracy of groundwater modeling in tidal lowland reclamation using extreme learning machine. *2014 2ND International Conference on Technology, Informatics, Management, Engineering, and Environment (TIME-E 2014)*, 228-233.
- Olewy, N. A.-H. H., y Hadi, A. K. (2021). Classifying quality of web services using Machine Learning classification and Cross Validation techniques. *Proceeding of 2021 2nd Information Technology to Enhance E-Learning And Other Application (IT-ELA 2021)*, 125-130. <https://doi.org/10.1109/IT-ELA52201.2021.9773416>
- Pandas. (2023). Pandas stable 1.5.3. Recuperado el 5 de febrero de 2023, de <https://pandas.pydata.org/>.

- Papacharalampous, G. A., y Tyralis, H. (2018a). Evaluation of random forests and Prophet for daily streamflow forecasting. *Advances in Geosciences*, 45, 201-208. <https://doi.org/10.5194/adgeo-45-201-2018>
- Papacharalampous, G., Tyralis, H., y Koutsoyiannis, D. (2018b). Predictability of monthly temperature and precipitation using automatic time series forecasting methods. *Acta Geophysica*, 66(4), 807-831. <https://doi.org/10.1007/s11600-018-0120-7>
- Papacharalampous, G., y Tyralis, H. (2020). Hydrological time series forecasting using simple combinations: Big data testing and investigations on one-year ahead river flow predictability. *Journal of Hydrology*, 590. <https://doi.org/10.1016/j.jhydrol.2020.125205>
- Papacharalampous, G., Tyralis, H., y Koutsoyiannis, D. (2019). Comparison of stochastic and machine learning methods for multi-step ahead forecasting of hydrological processes. *Stochastic Environmental Research and Risk Assessment*, 33(2), 481-514. <https://doi.org/10.1007/s00477-018-1638-6>
- Refaeilzadeh P. Tang, L. L. H. (2009). Cross-Validation. En M. T. LIU LING and ÖZSU (Ed.), *Encyclopedia of Database Systems* (pp. 532-538). Springer US. https://doi.org/10.1007/978-0-387-39940-9_565
- Requena, A. I., Jimenez-Alvarez, A., y Garcia, C. (2023). Assessment of climate change impact on maximum precipitation in Spain. *Hydrological Processes*, 37(1). <https://doi.org/10.1002/hyp.14803>
- Ritter, A., y Muñoz-Carpena, R. (2013). Performance evaluation of hydrological models: Statistical significance for reducing subjectivity in goodness-of-fit assessments. *Journal of Hydrology*, 480, 33-45. <https://doi.org/10.1016/j.jhydrol.2012.12.004>
- Roberts, W., Williams, G. P., Jackson, E., Nelson, E. J., y Ames, D. P. (2018). Hydrostats: A Python package for characterizing errors between observed and predicted time series. *Hydrology*, 5(4). <https://doi.org/10.3390/hydrology5040066>

- Romero Fresneda, R., Moreno García, J. V., Martínez Núñez, L., Huarte Itulain, M. T., Rodríguez Ballester, C., y Botey Fullat, R. (2020). Comportamiento de las precipitaciones en España y periodos de sequía (periodo 1961-2018). En *Comportamiento de las precipitaciones en España y periodos de sequía (periodo 1961-2018)*. Agencia Estatal de Meteorología. <https://doi.org/10.31978/666-20-006-0>
- Saboia, J. L. M. (1977). Autoregressive Integrated Moving Average (ARIMA) models for birth forecasting. *Journal of The American Statistical ASSOCIATION*, 72(358), 264-270. <https://doi.org/10.2307/2286787>
- Salas, J. D., Boes, D. C., Yevjevich, V., y Pegram, G. G. S. (1979). Hurst phenomenon as a pre-asymptotic behavior. En *Journal of Hydrology* (Vol. 44, Número 1).
- Salas, Delleur, J., Yevjevich, V., y Lane, W. L. (1980). *Applied Modeling of Hydrologic Time Series* (1st ed.). Water Resources Publications.
- Scikit-learn. (2023). Scikit-learn stable 1.2. Recuperado el 5 de febrero de 2023, de <https://scikit-learn.org/stable/>.
- Seager, R., Osborn, T. J., Kushnir, Y., Simpson, I. R., Nakamura, J., y Liu, H. (2019). Climate variability and change of Mediterranean-type climates. *Journal of Climate*, 32(10), 2887-2915. <https://doi.org/10.1175/JCLI-D-18-0472.1>
- Shoaib, M., Shamseldin, A. Y., Melville, B. W., y Khan, M. M. (2016). Hybrid Wavelet Neural Network Approach. En S. Shanmuganathan y S. Samarasinghe (Eds.), *ARTIFICIAL NEURAL NETWORK MODELLING* (Vol. 628, pp. 127-143). https://doi.org/10.1007/978-3-319-28495-8_7
- Speight, L. J., Cranston, M. D., White, C. J., y Kelly, L. (2021). Operational and emerging capabilities for surface water flood forecasting. *Wiley Interdisciplinary Reviews-Water*, 8(3). <https://doi.org/10.1002/wat2.1517>
- Statsmodels 0.13.5. (2023). Statsmodels. Recuperado el 5 de febrero de 2023, de <https://www.statsmodels.org/stable/index.html>.

- Tague, J. M., Nelson, M. J., y Murphy, L. J. (1975). ARIMA forecasts in information studies. *proceedings of the American Society for Information Science*, 12, 47-48.
- Taylor, S. J., y Letham, B. (2018). Forecasting at Scale. *PeerJ*. <https://doi.org/10.7287/peerj.preprints.3190v2>
- Valipour, M. (2015). Long-term runoff study using SARIMA and ARIMA models in the United States. *Meteorological Applications*, 22(3), 592-598. <https://doi.org/10.1002/met.1491>
- Wang, H. R., Wang, C., Lin, X., y Kang, J. (2014). An improved ARIMA model for hydrological simulations. *Nonlin. Processes Geophys. Discuss*, 1, 841-876. <https://doi.org/10.5194/npgd-1-841-2014>
- Xiao, Q., Zhou, L., Xiang, X., Liu, L., Liu, X., Li, X., y Ao, T. (2022). Integration of Hydrological model and time series model for improving the runoff simulation: A case study on BTOP model in Zhou River Basin, China. *Applied Sciences (Switzerland)*, 12(14). <https://doi.org/10.3390/app12146883>
- Yaseen, Z. M., Awadh, S. M., Sharafati, A., y Shahid, S. (2018). Complementary data-intelligence model for river flow simulation. *Journal of Hydrology*, 567, 180-190. <https://doi.org/10.1016/j.jhydrol.2018.10.020>